

Intelligence Artificielle

Enjeux et outils

CDC

SEPTEMBRE 2026



Objectifs de la formation

- Comprendre ce que sont les outils de machine learning et de deep learning, leur potentiel et leurs limites
- Avoir une vision à date de l'état de l'art de ces domaines
- Connaître et comprendre les applications de ces domaines à différents secteurs de l'industrie
- Maîtriser les méthodologies et connaître les outils propres aux projets d'intelligence artificielle
- Appréhender les enjeux juridiques et éthiques de l'IA
- Identifier les apports potentiels pour chaque métier, activité ou secteur dans l'entreprise

Programme



- 01** Qu'est-ce que l'IA ?
- 02** Réseaux de neurones et Deep Learning
- 03** Applications du Deep Learning
- 04** Quels problèmes peut-on résoudre avec le Machine Learning et avec le Deep Learning ?
- 05** Préparation d'un dataset
- 06** Recherche de la solution optimale
- 07** Les outils


01

Qu'est-ce que l'IA ?

Qu'est-ce que l'IA ?


L'intelligence artificielle et la réalité d'aujourd'hui

L'intelligence artificielle (IA) et l'apprentissage automatique (machine learning) représentent deux domaines interconnectés qui ont évolué de manière significative au fil de l'histoire, transformant la façon dont nous abordons la résolution de problèmes complexes et la prise de décisions.



Qu'est-ce que l'IA ?


L'intelligence artificielle et la réalité d'aujourd'hui



- **Intelligence artificielle** : Ensemble des théories et des techniques développant des programmes informatiques complexes capables de **simuler certains traits de l'intelligence humaine** (raisonnement, apprentissage...). Elles permettent donc à une machine de réaliser des tâches et de résoudre des problèmes normalement réservés aux humains
- **Machine Learning** : Discipline regroupant connaissances et méthodes permettant de donner aux systèmes informatiques la capacité à apprendre une tâche **sans être explicitement programmé** à cette fin.
- **Deep Learning** : Ensemble de méthodes de machine learning tentant de modéliser avec un **haut niveau d'abstraction** des données grâce à des architectures articulées de différentes transformations non linéaires.
- **Data science** : Discipline regroupant connaissances et méthodes permettant de **traiter des représentations** de faits stockés **sous forme numérique**.

Qu'est-ce que l'IA ?

L'intelligence artificielle et la réalité d'aujourd'hui




- Les premiers concepts d'IA remontent à l'Antiquité, avec des **mythes** et des histoires mettant en scène des **créatures artificielles douées d'intelligence**.
- Cependant, le véritable développement de l'IA a commencé au **XXe siècle** avec les travaux d'Alan Turing et sa machine universelle, qui a jeté les bases du calcul et de la pensée mécanique. Au cours des **années 1950 et 1960**, le terme *intelligence artificielle* a été popularisé, et des chercheurs ont entrepris de créer des programmes informatiques capables de simuler des processus de réflexion humaine.

« Toute activité intellectuelle peut être décrite avec suffisamment de précision pour être simulée par une machine » *John McCarthy (1927 – 2011)*

- Les premières ambitions de l'IA ont été confrontées à des défis techniques et conceptuels majeurs, ce qui a conduit à une période de réduction des attentes, connue sous le nom d'**hiver de l'IA**. Pendant ce temps, l'apprentissage automatique a commencé à émerger comme un sous-domaine de l'IA. Les **années 1980 et 1990** ont vu la résurgence de l'intérêt pour l'IA grâce à l'amélioration des capacités de calcul et à de nouvelles approches, notamment les réseaux neuronaux et les méthodes statistiques.

Qu'est-ce que l'IA ?



L'intelligence artificielle et la réalité d'aujourd'hui



- Le **début du XXIe siècle** a été marqué par une **accélération sans précédent dans les domaines de l'IA et de l'apprentissage automatique**. Les avancées dans les **algorithmes**, l'augmentation de la **puissance de calcul** et la disponibilité de **grandes quantités de données** ont ouvert de nouvelles possibilités. Les réseaux neuronaux profonds, en particulier les réseaux de neurones convolutionnels et les réseaux de neurones récurrents, ont donné naissance au domaine du deep learning, qui a révolutionné la vision par ordinateur, la compréhension du langage naturel et bien plus encore.
- De nos jours, l'IA et l'apprentissage automatique sont omniprésents, touchant presque tous les aspects de nos vies, des **moteurs de recherche** et des **recommandations** de contenu aux **voitures autonomes** et à la **médecine personnalisée**. Les systèmes d'IA sont devenus de plus en plus sophistiqués, capable de battre les champions mondiaux aux **échecs** et au **jeu de go**, ainsi que de traiter des quantités massives de données pour en extraire des informations précieuses.


Qu'est-ce que l'IA ?

L'intelligence artificielle et la réalité d'aujourd'hui



Qu'est-ce que l'IA ?

L'intelligence artificielle et la réalité d'aujourd'hui



Deep learning with COTS HPC systems

Adam Coates
Brody Huval
Tao Wang
David J. Wu
Andrew Y. Ng
Stanford University Computer Science Dept., 353 Serra Mall, Stanford, CA 94305 USA

ACOATES@CS.STANFORD.EDU
BH0DYH@STANFORD.EDU
TWANGCAT@STANFORD.EDU
DWU4@CS.STANFORD.EDU
ANG@CS.STANFORD.EDU


Bryan Catanzaro
NVIDIA Corporation, 2701 San Tomas Expressway, Santa Clara, CA 95050
BCATANZARO@NVIDIA.COM

Abstract


Scaling up deep learning algorithms has been shown to lead to increased performance in benchmark tasks and to enable discovery of complex high-level features. Recent efforts to train extremely large networks (with over 1 billion parameters) have relied on cloud-like computing infrastructure and thousands of CPU cores. In this paper, we present technical details and results from our own system based on Commodity Off-The-Shelf High Performance Computing (COTS HPC) technology: a cluster of GPU servers with Infini-band interconnects and MPI. Our system is able to train 1 billion parameter networks on

to detect objects when trained from unlabeled images alone (Coates et al., 2012; Le et al., 2012). The very largest of these systems has been constructed by Le et al. (Le et al., 2012) and Dean et al. (Dean et al., 2012), which is able to train neural networks with over 1 billion trainable parameters. While such extremely large networks are potentially valuable objects of AI research, the expense to train them is overwhelming: the distributed computing infrastructure (known as "DistBelief") used for the experiments in (Le et al., 2012) manages to train a neural network using 16000 CPU cores (in 1000 machines) in just a few days, yet this level of resource is likely beyond those available to most deep learning researchers. Less clear still is how to continue scaling significantly beyond this size

2012 : Deep Learning et GPUs




2015 : ImageNet challenge - de meilleurs résultats que l'homme dans la reconnaissance d'image grâce au Deep Learning




2016 : Microsoft annonce que son IA comprend la parole aussi bien qu'un humain

Qu'est-ce que l'IA ?

L'intelligence artificielle et la réalité d'aujourd'hui




Un schéma plus complet :



Qu'est-ce que l'IA ?

L'intelligence artificielle et la réalité d'aujourd'hui



A votre avis, combien d'emails** sont envoyés dans le monde en l'espace d'**une minute** ?**


De **SMS ?**



Qu'est-ce que l'IA ?

L'intelligence artificielle et la réalité d'aujourd'hui

Que se passe-t-il sur Internet en 1 minute ? (2021)




Crédit : L. Lewis

Qu'est-ce que l'IA ?

L'intelligence artificielle et la réalité d'aujourd'hui


Que se passe-t-il sur Internet en 1 minute ?



2021





2024



Qu'est-ce que l'IA ?


L'intelligence artificielle et la réalité d'aujourd'hui



- **Volume** : Croissance continue de la quantité de données à exploiter, souvent en téraoctets voire en pétaoctets.
- **Variété** : Traitement des données sous forme structurée et non structurée, devant faire l'objet d'une analyse dans leur ensemble (bases de données relationnelles, textes, données de capteurs, sons, vidéos...).
- **Vélocité** : Utilisation des données en temps réel dans de multiples applications (détection de fraude...).
- **Véracité** : Gestion de la fiabilité et de la véracité des données prédictives.

Qu'est-ce que l'IA ?


L'intelligence artificielle et la réalité d'aujourd'hui



Accès à l'information




Innovation technologique



Communication et connectivité

Qu'est-ce que l'IA ?

L'intelligence artificielle et la réalité d'aujourd'hui




Défis de l'information




Education et adaptation

Qu'est-ce que l'IA ?

Tâche intellectuelle versus algorithme




Nous cherchons à prédire la cible (quelle qu'elle soit) en utilisant les données disponibles.



Trouver une fonction f qui minimise la perte d'information ($\text{Loss}(f(X), y)$).

Qu'est-ce que l'IA ?

Tâche intellectuelle versus algorithme




Le Machine Learning peut se résumer à la recherche de la meilleure **fonction** $\hat{f}$ possible solution en f de l'équation :

$$y = f(X)$$

où :


- ➡ X est constitué par l'ensemble des données d'entrée (csv, texte, image, vidéo, audio...)
- ➡ y est l'ensemble des valeurs de sortie (qualitatives, ex. : hot dog, cat..., ou quantitatives, ex. : 38.3, 42 ans...)

$\hat{f}$ correspond au modèle : l'ensemble des algorithmes mis en œuvre pour estimer la valeur de sortie




Qu'est-ce que l'IA ?

Types de problématiques



Qu'est-ce que l'IA ?

Types de problématiques – new look



Qu'est-ce que l'IA ?

Types de problématiques

Apprentissage supervisé : répéter un exemple

- Un algorithme supervisé apprend à faire des prédictions ou des classifications en se basant sur des **données d'entraînement étiquetées**. Dans cette approche, l'ensemble de données utilisé pour l'entraînement est constitué d'**exemples d'entrée associés à leurs sorties souhaitées** ou étiquettes correspondantes.
- L'objectif de l'apprentissage supervisé est de permettre à l'algorithme de **généraliser les motifs à partir des données fournies**, puis d'**appliquer cette connaissance à de nouvelles données non vues pour réaliser des prédictions** ou des classifications précises.
- Le processus implique que l'algorithme ajuste de manière itérative ses paramètres internes afin de minimiser la différence entre ses prédictions et les étiquettes réelles dans les données d'entraînement. L'**algorithme apprend des écarts** et améliore progressivement sa capacité à réaliser des prédictions précises sur des données non vues.

Qu'est-ce que l'IA ?

Types de problématiques

Apprentissage supervisé : Le modèle apprend grâce aux labels associés aux données.

Exemple : Identifier si un champignon est dangereux ou comestible.



X : Couleur du pied, odeur, hauteur, présence d'un bulbe etc.

Y : Label « dangereux » ou « comestible »

Algorithmes d'apprentissage supervisé : k-plus proches voisins (KNN), régression logistique, arbre de décision, SVM ...


Qu'est-ce que l'IA ?

Types de problématiques

Apprentissage supervisé

L'apprentissage supervisé peut être catégorisé en deux types principaux : la classification et la régression.

- ➡ En **classification**, l'objectif est de prédire une étiquette catégorielle ou une **classe**.
- ➡ En **régression**, l'objectif est de prédire une **valeur numérique**.



Classification





Régression

Qu'est-ce que l'IA ?

Types de problématiques

A votre avis, classification ou régression ?



Qu'est-ce que l'IA ?


Types de problématiques

A votre avis, classification ou régression ?



Surface: 100m²


Localisation: Paris 14ème



Qu'est-ce que l'IA ?

Types de problématiques

A votre avis, classification ou régression ?



Qu'est-ce que l'IA ?

Types de problématiques


Apprentissage non supervisé : découvrir les données

- L'apprentissage non supervisé est une approche clé de l'apprentissage automatique où les algorithmes explorent des données **sans étiquettes ni réponses préexistantes**. Contrairement à l'apprentissage supervisé, où les données sont étiquetées, l'apprentissage non supervisé vise à **découvrir des structures** et des relations cachées au sein des données. Les algorithmes non supervisés sont utilisés pour des tâches telles que la **regroupement** (clustering) et la **réduction de dimensionnalité**.
- Dans le regroupement, les algorithmes identifient des motifs ou des groupes naturels dans les données en fonction de similarités entre les exemples. Par exemple, un algorithme de clustering pourrait **segmenter des clients** en groupes basés sur leurs comportements d'achat similaires, sans avoir besoin de connaître à l'avance les catégories de ces groupes.
- La réduction de dimensionnalité, quant à elle, permet de **simplifier les données** en réduisant le nombre de caractéristiques tout en préservant l'information essentielle. Cela facilite la visualisation et l'analyse des données complexes.
- L'apprentissage non supervisé est par exemple très utilisé en commerce et marketing via la segmentation de marché, et de clients, donc. Il permet de trouver des tendances, des structures et des regroupements significatifs dans les données, ce qui peut conduire à des découvertes utiles et à une meilleure compréhension des données sans nécessiter de directives préalables.

Qu'est-ce que l'IA ?

Types de problématiques



Apprentissage non supervisé : découvrir les données



Qu'est-ce que l'IA ?

Types de problématiques

Reinforcement learning : optimisation d'une récompense



- L'apprentissage par renforcement est une branche de l'apprentissage automatique qui se concentre sur l'apprentissage de la prise de décision **séquentielle**.

- Contrairement à l'apprentissage supervisé et non supervisé, où le modèle apprend à partir de données étiquetées ou non étiquetées, l'apprentissage par renforcement s'appuie sur des **interactions avec un environnement** pour améliorer ses performances au fil du temps.

Qu'est-ce que l'IA ?

Types de problématiques

Batch vs online learning

L'une des distinctions fondamentales dans la classification des systèmes d'apprentissage automatique réside dans leur capacité à **assimiler de manière incrémentale des flux de données en temps réel**.

Batch learning

Le batch learning (apprentissage par lots), implique de diviser les données d'entraînement en lots (batches) distincts et de **mettre à jour le modèle une fois que le modèle a été entraîné sur chaque lot**. Cela signifie que le modèle est mis à jour avec les gradients moyens calculés sur chaque lot. L'entraînement en batch peut nécessiter de stocker l'ensemble des données en mémoire pour calculer les gradients, ce qui peut être coûteux en termes de ressources, notamment pour de grandes quantités de données.


Online learning

L'online learning (apprentissage en ligne ou apprentissage incrémental), consiste à **mettre à jour le modèle à chaque nouvelle instance de données entrante**. Cela permet au modèle de s'adapter rapidement aux changements dans les données en temps réel. L'apprentissage en ligne est souvent utilisé lorsque les données arrivent de manière continue et que l'espace mémoire est limité.

Qu'est-ce que l'IA ?

Types de problématiques

Batch vs online learning




Qu'est-ce que l'IA ?

Types de problématiques

Apprentissage par transfert

- L'**apprentissage par transfert (transfer learning)** vise à appliquer des connaissances acquises lors de l'apprentissage sur une tâche source à une nouvelle tâche cible. Plutôt que de partir de zéro, l'apprentissage par transfert exploite les **informations préalablement apprises** pour accélérer et améliorer les performances de l'apprentissage sur la tâche cible. Cela est particulièrement utile lorsque les données d'entraînement sont rares ou coûteuses à collecter pour la nouvelle tâche.



Ce n'est pas un découpage « exclusif ». Le transfer learning peut être appliqué pour des tâches de classification de textes (apprentissage supervisé), de feature extraction...

Qu'est-ce que l'IA ?


Types de problématiques

Apprentissage séquentiel, apprentissage actif

- L'**apprentissage séquentiel (sequential learning)** concerne l'acquisition continue de connaissances et de compétences au fil du temps. Dans ce processus, le modèle apprend de nouvelles données tout en conservant et en utilisant les connaissances précédemment acquises. L'apprentissage séquentiel est couramment utilisé lorsque les données évoluent au fil du temps, et il permet au modèle de s'adapter aux changements et aux nouvelles informations de manière dynamique.
- L'**apprentissage actif (active learning)** est une approche qui permet au modèle de sélectionner de manière active les exemples les plus informatifs à étiqueter dans le but d'améliorer les performances du modèle. Plutôt que de se fier uniquement aux exemples aléatoires pour l'entraînement, l'apprentissage actif identifie les échantillons qui apporteront le plus d'informations pour ajuster le modèle. Cela réduit souvent le nombre d'exemples nécessaires pour atteindre une performance souhaitée.

Qu'est-ce que l'IA ?

Intelligence collective ou intelligence spécialisée ?




Qu'est-ce que l'IA ?

Machine Learning

Programmation classique :



Machine Learning :



Qu'est-ce que l'IA ?

Machine Learning – applications historiques



Qu'est-ce que l'IA ?

Machine Learning – applications historiques

PageRank

- Évalue la pertinence d'une page web en analysant les liens entrants de manière à attribuer un score de popularité, favorisant ainsi les pages reliées à un plus grand nombre de sources de qualité.
- Internet est modélisé comme un graphe probabiliste.
- Pas d'apprentissage automatique.
- Mais, quid du point d'entrée dans cette représentation de l'autorité et de la popularité des pages via leurs liens ?

Pour aller plus loin sur PageRank

Marche aléatoire, état stationnaire, matrices irréductibles et graphes connexes, théorème de Perron-Frobenius

<https://www.concours-centrale-supelec.fr/CentraleSupelec/2021/PSI/M051.pdf>

Qu'est-ce que l'IA ?

Machine Learning – applications historiques

RankBrain


- Il vise à comprendre le sens et la signification des requêtes de recherche.
- Il s'efforce de comprendre le **langage naturel** et les **intentions** derrière les requêtes des utilisateurs. Cela est particulièrement important car de nombreuses recherches sont formulées de manière complexe et ne reposent pas uniquement sur des mots-clés spécifiques. RankBrain analyse le contexte et les relations sémantiques entre les mots pour fournir des résultats de recherche plus pertinents. Il peut traiter des requêtes qu'il n'a jamais vues auparavant.
- Il parvient à faire cela en se basant sur des modèles d'apprentissage automatique (plus précisément de NLP).

RankBrain complète PageRank en améliorant la compréhension des requêtes complexes et en offrant des résultats plus précis et pertinents pour les utilisateurs.

Qu'est-ce que l'IA ?

Machine Learning – applications historiques

- Les courriers indésirables présentent souvent un taux élevé de termes tels que *Gagné*, *Offert*, *Riche*, *Héritage* et d'autres du même genre.
- Pour classifier un email (spam/non spam), il est possible d'utiliser le nombre d'occurrences de ces mots dans l'email, en utilisant par exemple un algorithme simple, comme Naive Bayes (on y revient dans la partie 5 !).



$$P(c | x) = \frac{P(x | c)P(c)}{P(x)}$$

Labels for the equation above:

- Likelihood points to $P(x | c)$
- Class Prior Probability points to $P(c)$
- Posterior Probability points to $P(c | x)$
- Predictor Prior Probability points to $P(x)$

$$P(c | X) = P(x_1 | c) \times P(x_2 | c) \times \dots \times P(x_n | c) \times P(c)$$

Qu'est-ce que l'IA ?


Machine Learning – applications historiques

La lecture automatique d'un chèque bancaire fait intervenir successivement plusieurs algorithmes de Machine Learning :

- ➡ **Détection des régions d'intérêt** : Identifier et extraire les régions pertinentes de l'image du chèque, telles que la zone où le montant est écrit, l'émetteur, le destinataire, etc.
- ➡ **Reconnaissance de caractères (OCR)** : Utiliser l'OCR pour convertir les caractères imprimés sur le chèque en texte numérique. Cela comprend la reconnaissance des numéros, des lettres et d'autres symboles.
- ➡ **Segmentation des champs & Traitement du Langage Naturel (NLP)** : Diviser les informations extraites en champs individuels, tels que le montant, la date, le nom du bénéficiaire, etc. Reconnaître et extraire automatiquement les informations (valeurs) derrière ces champs.

Qu'est-ce que l'IA ?

Applications - intelligence collective : agréger une connaissance partagée par des agents virtuels



Les chatbots

- Ce sont des applications automatisées conçues pour interagir avec les utilisateurs de manière conversationnelle. Ils vont fournir des **réponses instantanées**, des **informations** et des **solutions à diverses questions et requêtes**, le tout à travers des interfaces de messagerie ou d'autres canaux de communication.
- Ils utilisent des technologies de **traitement automatique du langage naturel** (NLP) pour comprendre le langage humain et générer des réponses appropriées.
- Les chatbots fonctionnent en suivant un **processus itératif**. Lorsqu'un utilisateur envoie un message ou une question, le chatbot utilise des algorithmes de NLP pour **analyser le texte** et **extraire le sens**. En fonction de cette analyse, le chatbot détermine la meilleure réponse ou l'action à entreprendre. Si le chatbot a déjà été **formé sur un ensemble de données** ou a **appris des interactions précédentes**, il peut fournir des réponses pertinentes. Dans le cas contraire, il peut poser des questions de clarification pour mieux comprendre la demande.

Qu'est-ce que l'IA ?

Applications - intelligence collective : agréger une connaissance partagée par des agents virtuels

Les chatbots

- Les chatbots peuvent être conçus pour des tâches spécifiques, telles que la **réservation de vols**, le **service client**, la **fourniture d'informations sur les produits**, la **prise de rendez-vous**...
- Ils peuvent être basés sur des **règles prédéfinies** ou utiliser des **modèles d'apprentissage automatique** pour améliorer leur capacité à comprendre et à répondre aux messages.



- Grâce à leur disponibilité 24/7 et à leur capacité à gérer de multiples conversations simultanées, les chatbots sont devenus au cours des dernières années des outils classiques pour les entreprises afin d'améliorer l'efficacité de l'assistance client, d'automatiser des processus et d'offrir une expérience utilisateur fluide.

Qu'est-ce que l'IA ?

Les différents types de données



Les données peuvent être catégorisées en trois types distincts : **structurées**, **semi-structurées** et **non structurées**. La variété de ces trois types de données pose des opportunités uniques mais également des défis en matière d'exploitation et d'analyse dans le domaine de l'intelligence artificielle.


Qu'est-ce que l'IA ?

Les différents types de données

- Les **données structurées** se présentent sous une forme organisée avec des **schémas prédéfinis**.
- Elles sont généralement stockées dans des **bases de données relationnelles** et se prêtent à une **analyse systématique** grâce à des requêtes SQL et d'autres méthodes.
- Il est estimé que les données structurées représentent environ **20 % à 30 % de l'ensemble des données disponibles**. Cependant, cette estimation varie considérablement en fonction de la source et de la méthodologie utilisées pour collecter et analyser les données. La part des données structurées diminue au fil du temps à mesure que de nouvelles sources de données non structurées continuent d'émerger.

Qu'est-ce que l'IA ?

Les différents types de données



Exemple de modèle de données d'une base relationnelle

Qu'est-ce que l'IA ?

Les différents types de données

- Les données semi-structurées ne suivent pas de schémas stricts, mais elles possèdent des **éléments de structure** qui permettent une certaine organisation.
- Elles sont couramment représentées au format JSON, XML ou dans des bases de données NoSQL.

```
1.  <?xml version = "1.0" encoding="UTF-8" standalone="yes"?>
2.  <document>
3.    <employee>
4.      <name>Alex</name>
5.      <age>22</age>
6.    </employee>
7.    <employee>
8.      <name>Bob</name>
9.      <age>24</age>
10.   </employee>
11.   <employee>
12.     <name>Emily</name>
13.     <age>32</age>
14.   </employee>
15. </document>
```

Qu'est-ce que l'IA ?

Les différents types de données

- Les données non structurées ne possèdent **pas de schéma ni de structure prédéfinis**. Cela inclut des formats comme le texte libre, les images, les vidéos et les fichiers audio.
- Les solutions de stockage dédiées aux données non structurées, comme les systèmes de fichiers distribués et les bases de données NoSQL, offrent la capacité de stocker et de gérer ces données à grande échelle. En outre, l'**indexation** et la **classification efficaces** sont essentielles pour faciliter la recherche et la récupération d'informations spécifiques au sein de ces données hétérogènes.
- Les données non structurées nécessitent souvent des **méthodes d'analyse** plus **avancées**, telles que le traitement du langage naturel ou la reconnaissance d'images, pour en extraire des informations significatives.

Qu'est-ce que l'IA ?

Différents scénarios : donnée tabulaire, texte, image, son (le début)

Texte – Bag of words

	about	bird	heard	is	the	word	you
About the bird, the bird, bird bird bird	1	5	0	0	2	0	0
You heard about the bird	1	1	1	0	1	0	1
The bird is the word	0	1	0	1	2	1	0

Qu'est-ce que l'IA ?

Différents scénarios : donnée tabulaire, texte, image, son (le début)

Texte – TFIDF

TF-IDF VECTORIZATION



	text	tf	idf
0	Eddard Stark is a king in the north.	1	3
1	A king but one king : kings are everywhere.	2	3
2	Hodor was different : he was not a king .	1	3
3	But the North could not change without him.	0	3

	king	was	the	not	a	he	one	north	kings	is	in	him	everywhere	A	different	could	change	but	are	Stark	North	Hodor	Eddard	
0	0.333333	0.0	0.5	0.0	0.5	0.0	0.0	0.0	1.0	0.0	1.0	1.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	1.0	0.0	0.0	1.0	
1	0.666667	0.0	0.0	0.0	0.0	0.0	0.0	1.0	0.0	1.0	0.0	0.0	0.0	1.0	1.0	0.0	0.0	0.0	1.0	1.0	0.0	0.0	0.0	0.0
2	0.333333	2.0	0.0	0.5	0.5	1.0	1.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	1.0	0.0	0.0	0.0	0.0	0.0	1.0	0.0	0.0
3	0.000000	0.0	0.5	0.5	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	1.0	0.0	0.0	0.0	1.0	1.0	0.0	0.0	0.0	1.0	0.0	0.0

Qu'est-ce que l'IA ?


Différents scénarios : donnée tabulaire, texte, image, son (le début)

Texte – Word2Vec, GloVe, FastText



Qu'est-ce que l'IA ?

Différents scénarios : données en temps réel (streaming data)



- Les données en streaming (ou en flux), désignent des informations qui sont générées et transmises en **temps réel**, au fur et à mesure de leur création. Un objet connecté est un dispositif qui **collecte** des données physiques du monde réel, les **transforme en signaux numériques** et les **transmet** via Internet vers d'autres appareils ou systèmes pour une analyse ultérieure ou une action en temps réel.
- Contrairement aux données statiques, ces flux sont continus et ne sont pas stockés de manière permanente.
- Les données en streaming proviennent de diverses sources telles que capteurs IoT, réseaux sociaux, transactions financières...
- Ce type de données est spécifique en raison de sa nature dynamique et évolutive, nécessitant des méthodes d'analyse en temps réel pour en extraire des connaissances utiles.

L'utilisation de données en streaming revêt une grande importance car elle permet une **réactivité immédiate aux événements en cours, la **détection d'anomalies** en temps réel, et la possibilité de prendre des **décisions rapides** bien qu'éclairées.** De plus, ces données fournissent des informations précieuses pour la **prévision de tendances**, l'**optimisation** des opérations commerciales et la **personnalisation** des expériences utilisateur, contribuant ainsi à une meilleure compréhension du monde en constante évolution dans lequel nous vivons.

Qu'est-ce que l'IA ?

Machine Learning – principaux algorithmes

Dans cette partie, nous allons parler de quelques algorithmes d'apprentissage automatique.

Nous n'allons pas parcourir tous les slides, ils sont là si vous souhaitez creuser un peu plus le sujet.

Qu'est-ce que l'IA ?


Machine Learning – principaux algorithmes

Régression linéaire simple = la régression linéaire comme au collège !

1.1.1. Ordinary Least Squares


`LinearRegression` fits a linear model with coefficients $w = (w_1, \dots, w_p)$ to minimize the residual sum of squares between the observed targets in the dataset, and the targets predicted by the linear approximation. Mathematically it solves a problem of the form:

$$\min_w \|Xw - y\|_2^2$$



$$\hat{y}_i = \alpha x_i + \beta$$

`LinearRegression` will take in its `fit` method arrays X , y and will store the coefficients w of the linear model in its `coef_` member:



$$y_i = \hat{y}_i + \varepsilon_i$$

$$\hat{\alpha} = \bar{y} - (\hat{\beta} \bar{x}),$$

$$\hat{\beta} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

Qu'est-ce que l'IA ?

Machine Learning – principaux algorithmes

Régression linéaire multiple = pareil, mais avec plusieurs x

$$y_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip} + \varepsilon_i$$

On préfère souvent la notation matricielle

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

$$\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}$$

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^T \\ \mathbf{x}_2^T \\ \vdots \\ \mathbf{x}_n^T \end{bmatrix} = \begin{bmatrix} 1 & x_{11} & \cdots & x_{1p} \\ 1 & x_{21} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & \cdots & x_{np} \end{bmatrix}$$

$$\boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \vdots \\ \beta_p \end{bmatrix}$$

$$\boldsymbol{\varepsilon} = \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$


$$\hat{\mathbf{a}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

est l'estimateur qui minimise la somme des carrés des erreurs (« estimateur des moindres carrés »).

Qu'est-ce que l'IA ?

Machine Learning – principaux algorithmes

Comment faire si on a des doutes sur les limites d'un modèle ? Et bien on se renseigne !



Aïe, premier écueil ! Vous vous souvenez de la définition de la multicolinéarité ? Lorsque les caractéristiques sont corrélées et que les colonnes présentent une dépendance linéaire approximative, ce qui rend la matrice de conception presque singulière. Cela rend l'estimation des moindres carrés très sensible aux erreurs aléatoires dans la cible observée, entraînant une grande variance. Cette situation de multicollinéarité peut se produire, par exemple, lorsque les données sont collectées sans un plan expérimental précis.

Pour aller plus loin : inversibilité de matrices.

Parfois, les coefficients de régression représentent des quantités physiques ou des valeurs métier (comme des comptages de fréquence ou des prix de produits) qui peuvent appartenir à un domaine borné. Avec cette formule, rien ne garantit de trouver des coefficients dans ce domaine.


Dans le cas bien particulier (mais possible) où les coefficients doivent être restreints à des valeurs positives, il est possible de passer à True le paramètre appelé "positive". Le modèle appliquera alors la méthode des moindres carrés non négatifs, ce qui permettra de maintenir des coefficients positifs dans le modèle.

Et bien sûr, tous les phénomènes modélisés ne suivent pas une loi linéaire ! C'est un modèle simpliste.

Qu'est-ce que l'IA ?

Machine Learning – principaux algorithmes

Régression polynômiale



Qu'est-ce que l'IA ?

Machine Learning – principaux algorithmes

LASSO (Least Absolute Shrinkage and Selection Operator)

1.1.3. Lasso

The **Lasso** is a linear model that estimates sparse coefficients. It is useful in some contexts due to its tendency to prefer solutions with fewer non-zero coefficients, effectively reducing the number of features upon which the given solution is dependent. For this reason, Lasso and its variants are fundamental to the field of compressed sensing. Under certain conditions, it can recover the exact set of non-zero coefficients (see [Compressive sensing: tomography reconstruction with L1 prior \(Lasso\)](#)).

Mathematically, it consists of a linear model with an added regularization term. The objective function to minimize is:

$$\min_w \frac{1}{2n_{\text{samples}}} \|Xw - y\|_2^2 + \alpha \|w\|_1$$

The lasso estimate thus solves the minimization of the least-squares penalty with $\alpha \|w\|_1$ added, where α is a constant and $\|w\|_1$ is the ℓ_1 -norm of the coefficient vector.



Puisque LASSO essaie de trouver un équilibre entre « petites » erreurs et « petits » coefficients, il doit parvenir à quantifier ce qui est « petit ». Pour cela, il est (beaucoup) plus pratique que les variables soient ramenées sur une **même échelle** (qu'elles soient « scalées »).

Qu'est-ce que l'IA ?

Machine Learning – principaux algorithmes

Régression logistique

La régression logistique décrit la modélisation d'une variable y à 2 modalités (1 ou 0, succès ou échec), via la probabilité sous-jacente de ces issues, en fonction de variables explicatives quantitatives.



$$h_{\theta}(x) = h(\theta_0 + \theta_1 x) = \frac{1}{1 + e^{-(\theta_0 + \theta_1 x)}}$$

Note : le cas binaire peut en réalité être étendu au cas multi-classe. Pour en apprendre plus, scikit-learn est notre ami : https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression

Qu'est-ce que l'IA ?

Machine Learning – principaux algorithmes

Classification – Naive Bayes

Cette fois, retour au lycée avec les probabilités conditionnelles !

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

Mais attention, ici nous sommes dans un cadre multivarié ! On rajoute l'**hypothèse de "naïveté"** selon laquelle les caractéristiques sont indépendantes les unes des autres, étant donné la classe. Dans l'exemple à suivre, cela signifie que le modèle suppose que la présence ou l'absence d'un mot dans un document n'est pas influencée par la présence ou l'absence d'autres mots.

Prenons l'exemple d'une classification de texte. On s'intéresse à la probabilité qu'un texte appartienne à une classe donnée, sachant ses mots.

On sait qu'on peut calculer cette probabilité à partir de la probabilité de chaque mot, celle de la classe ainsi que la probabilité de voir apparaître les mots en sachant la classe.


On estime ces probabilités par un calcul fréquentiel.

On peut donc en déduire la probabilité recherchée initialement.

Qu'est-ce que l'IA ?

Machine Learning – principaux algorithmes

Classification/régression – arbres de décision



Qu'est-ce que l'IA ?

Machine Learning – principaux algorithmes

Classification/régression – arbres de décision


Comment l'ordre des variables de décision est-il choisi ? Par leur pouvoir discriminant.

- Lors de la construction d'arbres de décision, le choix de l'**ordre de sélection des variables** est crucial pour obtenir des modèles performants.
- Les critères de décision des arbres de décision, tels que le Gini impurity ou l'entropie, se basent sur le **pouvoir discriminant** des variables pour déterminer celle qui divise le mieux les données en classes homogènes. L'algorithme commence généralement par la variable qui génère le gain d'impureté le plus élevé ou la réduction de l'entropie la plus significative. En d'autres termes, la variable qui permet de séparer au mieux les classes est choisie en premier, car elle apporte la plus grande contribution à la séparation des données en fonction de leur classe.
- L'ordre de sélection des variables peut varier en fonction du critère de décision utilisé, et il est influencé par la manière dont chaque critère mesure la pureté des nœuds. Les variables qui divisent les données de manière plus nette et plus pure sont préférées car elles permettent de créer des nœuds distincts avec une classe dominante. Cela conduit à une séparation plus efficace des classes au sein de l'arbre de décision final.

Qu'est-ce que l'IA ?

Machine Learning – principaux algorithmes

Classification/régression – Random Forest



Qu'est-ce que l'IA ?

Machine Learning – principaux algorithmes

Classification/régression – Random Forest

Quelle est la part « aléatoire » dans une forêt aléatoire ?

- ➡ la sélection des échantillons d'entraînement
- ➡ la sélection des caractéristiques utilisées

Échantillons d'entraînement : Plutôt que d'utiliser l'ensemble complet des données d'entraînement pour chaque arbre, une forêt aléatoire sélectionne aléatoirement un sous-ensemble d'observations pour chaque arbre. Cela s'appelle le bootstrap échantillonnage, où des échantillons sont tirés avec remplacement à partir des données d'entraînement. Cela introduit de l'aléatoire et garantit que chaque arbre est entraîné sur des données légèrement différentes, ce qui réduit l'overfitting potentiel.

Caractéristiques (variables) : Lors de la construction de chaque arbre, une forêt aléatoire sélectionne également un sous-ensemble aléatoire de caractéristiques à partir de l'ensemble complet de caractéristiques. Cela signifie que chaque arbre ne considère qu'un sous-ensemble des caractéristiques pour prendre des décisions, ce qui diversifie les arbres et réduit la corrélation entre eux.



Qu'est-ce que l'IA ?

Machine Learning – principaux algorithmes

Classification/régression - Support Vector Machines (SVM)

Le but est de trouver un hyperplan affine qui sépare « au mieux » en deux classes, où au mieux signifie à la fois :

- ➡ le plus grand nombre de points possible sont bien classifiés (tous si le problème est parfaitement linéairement séparable),
- ➡ la distance minimale des points au plan est maximale.




Qu'est-ce que l'IA ?

Machine Learning – principaux algorithmes

Classification/régression - Support Vector Machines (SVM)

Exemple avec un noyau polynômial



Degré 2 & dimension 2

$$\begin{aligned}x &= (x_1, x_2) & y &= (y_1, y_2) & \phi(x) &= (1, \sqrt{2}x_1, \sqrt{2}x_2, x_1^2, \sqrt{2}x_1x_2, x_2^2) \\ \langle \phi(x), \phi(y) \rangle &= 1 + 2x_1y_1 + 2x_2y_2 + x_1^2y_1^2 + 2x_1x_2y_1y_2 + x_2^2y_2^2 \\ &= (1 + x_1y_1 + x_2y_2)^2 \\ &= K(x, y)\end{aligned}$$

Qu'est-ce que l'IA ?

Machine Learning – principaux algorithmes

Classification/régression - Support Vector Machines (SVM)

Bonus pour les matheux

L'objectif principal d'un SVM est de trouver l'hyperplan (affine) de séparation maximal entre les données de différentes classes. Cela revient à trouver les poids et le biais (ou intercept) de l'hyperplan, qui peut être exprimé sous la forme d'une équation linéaire $w \cdot x + b = 0$, où w est le vecteur de poids, x est le vecteur d'entrée et b est le biais (qui peut éventuellement être inclus dans le produit $w \cdot x + b$ en prenant $x_0 = 1$ et $w_0 = b$).

Dans les calculs engendrés par ce processus, les produits scalaires sont prédominants :


Fonction de décision : L'équation de l'hyperplan est utilisée pour prendre des décisions de classification. Le signe du produit scalaire permet de déterminer de quel côté le point se situe.

Vecteurs de support : Les vecteurs de support sont les points de données les plus proches de l'hyperplan de séparation. Ils jouent un rôle crucial dans la définition de l'hyperplan optimal. Les produits scalaires entre les vecteurs de support et le vecteur de poids sont utilisés pour calculer la marge et optimiser la position de l'hyperplan.

Lagrangien et problème dual : L'optimisation des SVM est formulée comme un problème de programmation quadratique convexe, où les produits scalaires entre les vecteurs de données et le vecteur de poids apparaissent dans la fonction objectif et les contraintes. Le problème dual des SVM repose également sur les produits scalaires et permet de trouver efficacement les coefficients de Lagrange optimaux.

Qu'est-ce que l'IA ?

Bagging et boosting



Qu'est-ce que l'IA ?


Machine Learning – principaux algorithmes

Classification/régression – Gradient Boosting

Appartient à la famille des techniques d'ensemble, qui visent à **combiner les prédictions de plusieurs modèles simples** pour améliorer la performance globale. Le gradient boosting a gagné en popularité grâce à sa capacité à produire des modèles hautement précis et flexibles pour des tâches de régression et de classification.

Le gradient boosting fonctionne en entraînant itérativement une séquence de modèles dits **faibles** (généralement des arbres de décision peu profonds) tout en ajustant les prédictions pour corriger les erreurs du modèle précédent.

L'idée clé du gradient boosting est de minimiser la fonction de perte en ajustant les prédictions successivement pour se rapprocher des vraies valeurs. Le terme "gradient" provient du fait que les résidus sont ajustés dans la direction qui minimise la perte.



Qu'est-ce que l'IA ?

Machine Learning – principaux algorithmes

Classification/régression – Gradient Boosting

Méthode itérative : Le boosting implique l'entraînement itératif de modèles faibles (souvent des arbres de décision peu profonds) en accordant plus de poids aux exemples mal classés par les modèles précédents.

Correction des erreurs : Les modèles successifs sont ajustés pour corriger les erreurs commises par les modèles précédents. Ils se concentrent sur les exemples mal classés, améliorant ainsi la performance globale.

Agrégation adaptative : Les prédictions des modèles faibles sont agrégées en donnant plus de poids aux modèles qui performant mieux sur les exemples difficiles.

XGBoost, LightGBM et AdaBoost sont des exemples populaires de méthodes de boosting.

Qu'est-ce que l'IA ?

Machine Learning – principaux algorithmes

Classification/régression – Gradient Boosting

Initialisation : Le processus commence avec la création d'un modèle faible, souvent appelé "estimateur de base". Cela pourrait être un simple arbre de décision avec une profondeur limitée.

Calcul des résidus : Les prédictions du modèle actuel sont comparées aux vraies valeurs de la cible, et les résidus (différences entre les prédictions et les vraies valeurs) sont calculés. Le modèle suivant sera alors ajusté pour prédire ces résidus.

Construction du modèle : Un nouveau modèle est ajusté pour prédire les résidus calculés précédemment. Cela peut être considéré comme une correction apportée au modèle précédent pour se rapprocher davantage des vraies valeurs.


Mise à jour des prédictions : Les prédictions du modèle actuel sont combinées avec les prédictions des modèles précédents, ce qui donne une prédiction globale. Cette mise à jour des prédictions aide à réduire l'erreur résiduelle.

Répétition : Les étapes 2 à 4 sont répétées pour un certain nombre d'itérations. À chaque étape, un nouveau modèle est ajouté à l'ensemble pour améliorer les prédictions.

Qu'est-ce que l'IA ?

Machine Learning – principaux algorithmes

Segmentation



Qu'est-ce que l'IA ?

Machine Learning – principaux algorithmes

Segmentation par partitionnement (k-means)

L'algorithme du k-means travaille avec les **centroïdes des groupes**.


Initialisation : On « pioche » au hasard les centroïdes parmi les points de données.

On calcule la **distance** entre tous les **points** et chaque **centroïde**.

On attribue le point au **centroïde le plus proche**.

On calcule les **nouvelles coordonnées des centroïdes** à partir des points le constituant.

Illustration : <https://www.youtube.com/watch?v=5I3Ei69I40s>



Qu'est-ce que l'IA ?

Machine Learning – principaux algorithmes

Segmentation par partitionnement (k-means)

- **Type de regroupement** : Regroupement par partitionnement, où les données sont réparties en K groupes en minimisant la somme des carrés des distances entre les points et les centres de groupe.
- **Nombre de clusters** : L'utilisateur doit spécifier le nombre de clusters K à l'avance, ce qui peut être un défi.
- **Forme des clusters** : K-means tend à créer des clusters convexes et de taille similaire, ce qui peut ne pas être optimal pour des données avec des formes complexes ou de tailles variées.
- **Sensibilité aux points initiaux** : Le choix initial des centres de cluster peut influencer les résultats, car l'algorithme peut converger vers différents optima locaux.

Qu'est-ce que l'IA ?

Machine Learning – principaux algorithmes

Segmentation par densité (DBSCAN)


DBSCAN (Density-Based Spatial Clustering of Applications with Noise) est un algorithme simple qui définit des clusters en utilisant l'**estimation de la densité locale**. On peut le diviser en 4 étapes :

Pour chaque observation on regarde le nombre de points à au plus une distance ϵ de celle-ci. On appelle cette zone le **ϵ -voisinage de l'observation**.

Si une observation compte au moins un certain nombre de voisins, elle est considérée comme une **observation cœur**. On a alors décelé une **observation à haute densité**.

Toutes les observations au voisinage d'une observation cœur appartiennent au même cluster. Il peut y avoir des observations cœur proche les unes des autres. **Par conséquent de proche en proche on obtient une longue séquence d'observations cœur qui constitue un unique cluster.**

Toute observation qui n'est pas une observation cœur et qui ne comporte pas d'observation cœur dans son voisinage est considérée comme une **anomalie**.



Qu'est-ce que l'IA ?

Machine Learning – principaux algorithmes

Segmentation par densité (DBSCAN)

- **Type de regroupement** : Basé sur la densité, qui identifie les régions de haute densité comme clusters et les régions de faible densité comme bruit.
- **Nombre de clusters** : Ne nécessite pas de spécifier le nombre de clusters à l'avance, ce qui le rend plus adapté aux situations où le nombre de clusters est inconnu.
- **Forme des clusters** : Peut identifier des clusters de forme arbitraire et peut gérer des clusters de tailles différentes.
- **Détection de bruit** : Peut détecter et ignorer les points aberrants ou les bruits, ce qui est utile dans des données réelles avec des valeurs aberrantes..

Qu'est-ce que l'IA ?

Machine Learning – principaux algorithmes

Segmentation hiérarchique (ascendante)

Initialisation : Chaque point de données est initialement considéré comme un cluster individuel.


Calcul des distances : Les distances entre toutes les paires de clusters sont calculées en utilisant une mesure de similarité, comme la distance euclidienne pour des données numériques ou des mesures appropriées pour des données catégoriques.

Fusion des clusters : Les deux clusters les plus similaires sont fusionnés pour former un nouveau cluster. La similarité entre les clusters peut être déterminée en fonction de la distance entre les points, généralement la plus petite, la plus grande ou la moyenne des distances.

Répétition : Les étapes de calcul des distances et de fusion des clusters sont répétées jusqu'à ce qu'un seul cluster contenant tous les points soit obtenu.

Construction de dendrogramme : Un dendrogramme est construit pour visualiser la hiérarchie des clusters. Les branches du dendrogramme montrent les regroupements successifs des clusters.


Choix du nombre de clusters : En coupant le dendrogramme à un certain niveau, on peut obtenir différents nombres de clusters. Ce niveau de coupe détermine combien de clusters on souhaite obtenir.




Qu'est-ce que l'IA ?

Machine Learning – principaux algorithmes

Segmentation hiérarchique (ascendante)



Cluster Dendrogram



Qu'est-ce que l'IA ?

Machine Learning – principaux algorithmes


Segmentation hiérarchique (ascendante)

- **Type de regroupement** : Crée une hiérarchie de clusters, où les groupes sont agglomérés (ascendant) ou divisés (descendant) en fonction de la similarité.
- **Nombre de clusters** : La segmentation hiérarchique ne nécessite pas de définir le nombre de clusters à l'avance. L'utilisateur peut choisir le nombre en fonction du niveau de découpage dans l'arbre.
- **Visualisation** : La segmentation hiérarchique peut être visualisée sous forme d'un dendrogramme, ce qui permet de comprendre les relations entre les clusters à différents niveaux.
- **Calcul intensif** : Les méthodes hiérarchiques peuvent être plus intensives en termes de calcul, surtout pour de grandes quantités de données.

Qu'est-ce que l'IA ?

Machine Learning – principaux algorithmes

Choisir sa méthode de segmentation



Qu'est-ce que l'IA ?

Machine Learning – principaux algorithmes




Activité :
Retrouver le principe d'un algorithme

Qu'est-ce que l'IA ?

Machine Learning – principaux algorithmes

Sur la base de ce schéma, proposer un mode opératoire pour classer en A ou B un point de classe inconnue.





02

Réseaux de neurones et Deep Learning


Réseaux de neurones et Deep Learning

Qu'est-ce qu'un réseau de neurones ?



Réseaux de neurones et Deep Learning

Qu'est-ce qu'un réseau de neurones ?



07

**Les outils (spoiler) –
un premier outil de
« bas niveau »**

Les outils


Frameworks de Deep Learning



TensorFlow

Réseaux de neurones et Deep Learning

Tensorflow playground




<https://playground.tensorflow.org>

Réseaux de neurones et Deep Learning

Le réseau de neurones : architecture, fonctions d'activation et de pondération


ANN



Réseaux de neurones et Deep Learning

Le réseau de neurones : architecture, fonctions d'activation et de pondération


ANN



Réseaux de neurones et Deep Learning

Le réseau de neurones : architecture, fonctions d'activation et de pondération


ANN



Réseaux de neurones et Deep Learning

Le réseau de neurones : architecture, fonctions d'activation et de pondération


ANN



Réseaux de neurones et Deep Learning

Le réseau de neurones : architecture, fonctions d'activation et de pondération


ANN



Réseaux de neurones et Deep Learning

Le réseau de neurones : architecture, fonctions d'activation et de pondération


ANN



Réseaux de neurones et Deep Learning

Le réseau de neurones : architecture, fonctions d'activation et de pondération


ANN



Réseaux de neurones et Deep Learning

Le réseau de neurones : architecture, fonctions d'activation et de pondération


ANN



Réseaux de neurones et Deep Learning

Le réseau de neurones : architecture, fonctions d'activation et de pondération


Que fait une fonction d'activation ?



Réseaux de neurones et Deep Learning

Le réseau de neurones : architecture, fonctions d'activation et de pondération


Que fait une fonction d'activation ?



Réseaux de neurones et Deep Learning

Le réseau de neurones : architecture, fonctions d'activation et de pondération

Que fait une fonction d'activation ?



Réseaux de neurones et Deep Learning

Le réseau de neurones : architecture, fonctions d'activation et de pondération

Que fait une fonction d'activation ?

Une fonction d'activation convertit un ANN linéaire en un réseau non linéaire.

- Une fonction d'activation dans un ANN ajoute de la **non-linéarité** aux calculs effectués dans les couches de neurones.
- Sans fonction d'activation, la sortie serait simplement une combinaison linéaire des entrées, quelle que soit la complexité ou le nombre de couches cachées du modèle.
- Cela limiterait fortement la capacité du réseau à résoudre des problèmes complexes nécessitant une approche non linéaire.
- Pour cette raison, la fonction d'activation transforme la somme pondérée des entrées en ajoutant cette non-linéarité, permettant au réseau de capturer des relations complexes dans les données et d'apprendre à mieux classer ou prédire des informations.

Réseaux de neurones et Deep Learning

Le réseau de neurones : architecture, fonctions d'activation et de pondération

Que fait une fonction d'activation ?

Elle améliore la rétropropagation en créant une dérivée dépendant de l'entrée (la plupart du temps)

Lorsque la rétropropagation se déroule, les gradients calculés pour chaque poids dans chaque couche sont différents, en fonction de la valeur actuelle des neurones et de l'erreur observée. Cela permet au réseau de mieux ajuster ses poids, car le gradient fournit des informations spécifiques au contexte des données actuelles, plutôt qu'un ajustement global uniforme comme dans le cas linéaire.

➡ Nous reviendrons sur la rétropropagation plus tard.

Réseaux de neurones et Deep Learning

Le réseau de neurones : architecture, fonctions d'activation et de pondération

Caractéristiques (possibles) d'une fonction d'activation


- **Non-linéarité**. Un réseau neuronal (même à 2 couches) va alors pouvoir être considéré comme un approximateur de fonction universel.
- **Caractère différentiable** (partout). Cela permet de créer des optimisations basées sur les gradients.
- **Étendue** (espace image). Quand la plage d'activation est finie, les méthodes d'apprentissage basées sur les gradients sont plus stables. Quand la plage est infinie, l'apprentissage est généralement plus efficace.
- **Monotonie**. Si la fonction d'activation est monotone et que la fonction de perte est convexe, alors la surface d'erreur résultante est convexe dans un réseau monocouche.
- **Dérivée monotone**. Cela permet une meilleure capacité à généraliser (dans certains cas).
- **Tangence (équivalence) à l'identité en 0**. Si la fonction ne converge pas vers l'identité en 0, alors un soin spécial doit être apporté lors de l'initialisation des poids.

Réseaux de neurones et Deep Learning

Le réseau de neurones : architecture, fonctions d'activation et de pondération

Fonctions d'activation usuelles

Identité (rampe)



$$f(x) = x$$

$$f'(x) = 1$$


Ensemble image	Classe de continuité	Monotone	Dérivée monotone	Equivalence à l'identité en 0
$\mathbb{R}$	$\mathcal{C}^\infty$	Oui	Oui	Oui

Réseaux de neurones et Deep Learning

Le réseau de neurones : architecture, fonctions d'activation et de pondération

Fonctions d'activation usuelles

Marche (Heaviside)



$$f(x) = \begin{cases} 0 & \text{si } x < 0 \\ 1 & \text{si } x > 0 \end{cases}$$

$$f'(x) = 0 \text{ si } x \neq 0$$


Ensemble image	Classe de continuité	Monotone	Dérivée monotone	Equivalence à l'identité en 0
$\{0;1\}$	$\mathcal{C}^{-1}$	Oui	Non	Non

Réseaux de neurones et Deep Learning

Le réseau de neurones : architecture, fonctions d'activation et de pondération

Fonctions d'activation usuelles

Logistique (sigmoïde)



$$f(x) = \frac{1}{1 + e^{-x}}$$

$$f'(x) = f(x)(1 - f(x))$$

Ensemble image	Classe de continuité	Monotone	Dérivée monotone	Equivalence à l'identité en 0
$[0;1]$	$\mathcal{C}^\infty$	Oui	Non	Non

Réseaux de neurones et Deep Learning

Le réseau de neurones : architecture, fonctions d'activation et de pondération

Fonctions d'activation usuelles

Logistique (sigmoïde)

« Avantages »

- Sortie bornée
- Lissage des résultats / différentiabilité
- Compréhension intuitive

« Inconvénients »

- Plateaux lors de l'apprentissage (saturation de gradient)
- Pas centrée autour de zéro
- Problèmes de calcul exponentiel



<https://www.v7labs.com/blog/neural-networks-activation-functions>

Réseaux de neurones et Deep Learning

Le réseau de neurones : architecture, fonctions d'activation et de pondération

Fonctions d'activation usuelles

Softmax




Réseaux de neurones et Deep Learning

Le réseau de neurones : architecture, fonctions d'activation et de pondération

Fonctions d'activation usuelles

Tangente hyperbolique



$$f(x) = \tanh(x) = \frac{2}{1 + e^{-2x}} - 1$$

$$f'(x) = 1 - f(x)^2$$


Ensemble image	Classe de continuité	Monotone	Dérivée monotone	Equivalence à l'identité en 0
$[-1;1]$	$\mathcal{C}^\infty$	Oui	Non	Oui

Réseaux de neurones et Deep Learning

Le réseau de neurones : architecture, fonctions d'activation et de pondération

Fonctions d'activation usuelles

Arc tangente



$$f(x) = \tan^{-1}(x)$$

$$f'(x) = \frac{1}{x^2 + 1}$$


Ensemble image	Classe de continuité	Monotone	Dérivée monotone	Equivalence à l'identité en 0
$\left[-\frac{\pi}{2}; \frac{\pi}{2}\right]$	$\mathcal{C}^\infty$	Oui	Non	Oui

Réseaux de neurones et Deep Learning

Le réseau de neurones : architecture, fonctions d'activation et de pondération

Fonctions d'activation usuelles

Soft sign (« signe doux »)



$$f(x) = \frac{x}{1 + |x|}$$

$$f'(x) = \frac{1}{(1 + |x|)^2}$$


Ensemble image	Classe de continuité	Monotone	Dérivée monotone	Equivalence à l'identité en 0
$[-1;1]$	$\mathcal{C}^1$	Oui	Non	Oui

Réseaux de neurones et Deep Learning

Le réseau de neurones : architecture, fonctions d'activation et de pondération

Fonctions d'activation usuelles

ReLU (unité de rectification linéaire)



$$f(x) = \begin{cases} 0 & \text{si } x < 0 \\ x & \text{si } x \geq 0 \end{cases}$$

$$f'(x) = \begin{cases} 0 & \text{si } x < 0 \\ 1 & \text{si } x \geq 0 \end{cases}$$




Ensemble image	Classe de continuité	Monotone	Dérivée monotone	Equivalence à l'identité en 0
?	?	?	?	?

Réseaux de neurones et Deep Learning

Le réseau de neurones : architecture, fonctions d'activation et de pondération

Fonctions d'activation usuelles

ReLU (unité de rectification linéaire)



$$f(x) = \begin{cases} 0 & \text{si } x < 0 \\ x & \text{si } x \geq 0 \end{cases}$$

$$f'(x) = \begin{cases} 0 & \text{si } x < 0 \\ 1 & \text{si } x \geq 0 \end{cases}$$


Ensemble image	Classe de continuité	Monotone	Dérivée monotone	Equivalence à l'identité en 0
$\mathbb{R}^+$	$\mathcal{C}^0$	Oui	Oui	A droite

Réseaux de neurones et Deep Learning

Le réseau de neurones : architecture, fonctions d'activation et de pondération

Fonctions d'activation usuelles

PReLU (unité de rectification linéaire paramétrique)



$$f(x) = \begin{cases} \alpha x & \text{si } x < 0 \\ x & \text{si } x \geq 0 \end{cases}$$

$$f'(x) = \begin{cases} \alpha & \text{si } x < 0 \\ 1 & \text{si } x \geq 0 \end{cases}$$


Ensemble image	Classe de continuité	Monotone	Dérivée monotone	Equivalence à l'identité en 0
$\mathbb{R}$	$\mathcal{C}^0$	Oui	Oui	A droite

Réseaux de neurones et Deep Learning

Le réseau de neurones : architecture, fonctions d'activation et de pondération

Fonctions d'activation usuelles

ELU (unité exponentielle linéaire)



$$f(x) = \begin{cases} \alpha(e^x - 1) & \text{si } x < 0 \\ x & \text{si } x \geq 0 \end{cases}$$

$$f'(x) = \begin{cases} f(x) + \alpha & \text{si } x < 0 \\ 1 & \text{si } x \geq 0 \end{cases}$$


Ensemble image	Classe de continuité	Monotone	Dérivée monotone	Equivalence à l'identité en 0
$[-\alpha; +\infty[$	$\mathcal{C}^1$ si $\alpha = 1$ $\mathcal{C}^0$ sinon	Oui	Oui	Oui ssi $\alpha = 1$

Réseaux de neurones et Deep Learning

Le réseau de neurones : architecture, fonctions d'activation et de pondération

Fonctions d'activation usuelles

SoftPlus (« ReLU douce »)



$$f(x) = \ln(1 + e^x)$$

$$f'(x) = \frac{1}{1 + e^{-x}}$$


Ensemble image	Classe de continuité	Monotone	Dérivée monotone	Equivalence à l'identité en 0
$\mathbb{R}^+$	$\mathcal{C}^\infty$	Oui	Oui	Non

Réseaux de neurones et Deep Learning

Le réseau de neurones : architecture, fonctions d'activation et de pondération

Fonctions d'activation usuelles

Identité courbée



$$f(x) = \frac{\sqrt{x^2 + 1} - 1}{2} + x$$

$$f'(x) = \frac{x}{2\sqrt{x^2 + 1}} + 1$$


Ensemble image	Classe de continuité	Monotone	Dérivée monotone	Equivalence à l'identité en 0
$\mathbb{R}$	$\mathcal{C}^\infty$	Oui	Oui	Oui

Réseaux de neurones et Deep Learning

Le réseau de neurones : architecture, fonctions d'activation et de pondération

Fonctions d'activation usuelles

Soft exponential



$$f(x) = \begin{cases} -\frac{\ln(1-\alpha(x+\alpha))}{\alpha} & \text{si } \alpha < 0 \\ x & \text{si } \alpha = 0 \\ \frac{e^{\alpha x}-1}{\alpha} + \alpha & \text{si } \alpha > 0 \end{cases}$$

$$f'(x) = \begin{cases} \frac{1}{1-\alpha(\alpha+x)} & \text{si } \alpha < 0 \\ e^{\alpha x} & \text{si } \alpha \geq 0 \end{cases}$$


Ensemble image	Classe de continuité	Monotone	Dérivée monotone	Equivalence à l'identité en 0
$\mathbb{R}$	$\mathcal{C}^\infty$	Oui	Oui	Oui ssi $\alpha = 0$

Réseaux de neurones et Deep Learning

Le réseau de neurones : architecture, fonctions d'activation et de pondération

Fonctions d'activation usuelles

Swish / SiLU



$$f(x) = x \operatorname{sigmoid}(\beta x) = \frac{x}{1 + e^{-\beta x}}$$

$$f'(x) = \frac{1 + e^{-\beta x} + \beta x e^{-\beta x}}{(1 + e^{-\beta x})^2}$$

Ensemble image	Classe de continuité	Monotone	Dérivée monotone	Equivalence à l'identité en 0
Dépend de β ($]-e; +\infty[$ si $\beta=1$)	$\mathcal{C}^\infty$	Non	Non	Non

Réseaux de neurones et Deep Learning

Le réseau de neurones : architecture, fonctions d'activation et de pondération

Fonctions d'activation paires (sinus cardinal, gaussienne)

Les fonctions d'activation paires, comme les fonctions gaussienne et sinc, sont peu courantes dans les réseaux de neurones classiques de type feedforward, mais elles sont utiles dans certains types de réseaux et domaines spécifiques.

- ➡ Les fonctions **gaussiennes** ($f(x) = e^{-x^2}$) sont centrales dans les **RBFN** (réseaux de neurones à fonction de base radiale). Dans ces réseaux, les neurones cachés s'activent en fonction de la distance entre l'entrée et un point « centre » spécifique. Ce type de réseau est efficace pour les tâches où le regroupement spatial des données est pertinent, comme l'**interpolation**, l'**approximation de fonctions** et certaines **classifications**.
- ➡ Des fonctions comme le **sinus cardinal** ($f(x) = \frac{\sin(x)}{x}$) apparaissent dans les réseaux de neurones basés sur les **ondelettes** (généralisation des séries, par exemple de Fourier). Ces réseaux sont utilisés pour modéliser des données avec des motifs **oscillatoires**, ce qui est pertinent en **analyse de fréquences**, **traitement du signal** et **extraction de caractéristiques dans les séries temporelles**.

Réseaux de neurones et Deep Learning

Le réseau de neurones : architecture, fonctions d'activation et de pondération

Fonctions à base radiale

La fonction gaussienne fait en réalité partie d'une catégorie particulière de fonctions d'activation : les **fonctions à base radiale** (RBF). Celles-ci sont employées dans les RBFN, connus pour leur grande efficacité en tant qu'approximateurs universels de fonctions.

$$\text{Fonction gaussienne : } \phi(v_i) = \exp\left(-\frac{\|v_i - c_i\|^2}{2a^2}\right)$$

$$\text{Fonction multiquadratique : } \phi(v_i) = \sqrt{\|v_i - c_i\|^2 + a^2}$$


$$\text{Fonction multiquadratique inverse: } \phi(v_i) = \frac{1}{\sqrt{\|v_i - c_i\|^2 + a^2}}$$

Pour les plus attentifs : ce sont effectivement ces fonctions qu'on retrouve comme noyaux possibles dans les SVM.

Réseaux de neurones et Deep Learning

L'apprentissage d'un réseau de neurones : fonctions de coût, back-propagation, SGD

ANN



Réseaux de neurones et Deep Learning

L'apprentissage d'un réseau de neurones : fonctions de coût, back-propagation, SGD

Fonctions de coût pour la régression

MSE, erreur quadratique moyenne (moyenne des carrés des erreurs) $MSE = \frac{1}{n} \sum_{i=1}^n e_i^2 = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$

RMSE, racine de l'erreur quadratique moyenne $RMSE = \sqrt{MSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$

- ➡ Ces métriques **pénalisent les grandes erreurs plus fortement** que les petites erreurs (ce peut être un avantage comme un inconvénient). En particulier, elles sont très sensibles aux outliers.
- ➡ Ces métriques sont **facilement optimisables**. Elles sont dérivables et peuvent être utilisées avec des algorithmes à base de gradient. Dans certains problèmes, on peut même obtenir une solution explicite sans avoir à faire d'optimisation stochastique (ex. : OLS).

Réseaux de neurones et Deep Learning

L'apprentissage d'un réseau de neurones : fonctions de coût, back-propagation, SGD

Fonctions de coût pour la régression

MAE, erreur absolue moyenne :
$$\text{MAE} = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i|$$

➡ Elle est moins sensible aux valeurs aberrantes, car elle ne met pas autant l'accent sur les grandes erreurs., mais elle peut donner des gradients qui ne convergent pas toujours efficacement. La MAE n'est en pratique quasiment jamais utilisée en tant que telle, mais elle est plutôt combinée avec d'autres fonctions de coût comme la MSE :

$$\text{Huber Loss} = \begin{cases} \frac{1}{2}(y_i - \hat{y}_i)^2 & \text{si } |y_i - \hat{y}_i| \leq \delta \\ \delta \cdot |y_i - \hat{y}_i| - \frac{1}{2}\delta^2 & \text{sinon} \end{cases}$$

$$\text{Log-Cosh Loss} = \sum_{i=1}^N \log(\cosh(\hat{y}_i - y_i))$$

Réseaux de neurones et Deep Learning

L'apprentissage d'un réseau de neurones : fonctions de coût, back-propagation, SGD

D'autres fonctions de coût pour la régression (peu utilisées)

MAPE, erreur absolue moyenne en pourcentage :
$$\text{MAPE} = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \times 100$$

MSLE, erreur quadratique moyenne logarithmique :
$$\text{MSLE} = \frac{1}{n} \sum_{i=1}^n (\log(1 + y_i) - \log(1 + \hat{y}_i))^2$$



Réseaux de neurones et Deep Learning

L'apprentissage d'un réseau de neurones : fonctions de coût, back-propagation, SGD

Fonctions de coût pour la classification

Binary cross-entropy :
$$\text{Log Loss} = -\frac{1}{n} \sum_{i=1}^n (y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i))$$

Categorical cross-entropy :
$$\text{Cross-Entropy} = -\sum_{i=1}^n \sum_{k=1}^K y_{i,k} \log(\hat{y}_{i,k})$$

Kullback-Leibler divergence :
$$D_{KL}(P \parallel Q) = \sum_i P(i) \log \left(\frac{P(i)}{Q(i)} \right)$$

- ➡ Ces fonctions ne sont pas symétriques, mais ce n'est pas un problème en pratique.
- ➡ On peut tenir compte d'un déséquilibre de coût/de classe : poids, focal loss...

Réseaux de neurones et Deep Learning

L'apprentissage d'un réseau de neurones : fonctions de coût, back-propagation, SGD

D'autres fonctions de coût

- **Temporal difference error** et **Reward prediction error** pour l'apprentissage par renforcement
- **Perceptual Loss**
- **Contrastive Loss**

Réseaux de neurones et Deep Learning


L'apprentissage d'un réseau de neurones : fonctions de coût, back-propagation, SGD

Exemples d'associations de fonctions d'activation (pour la dernière couche) et de perte

- Si on utilise une fonction d'activation sigmoïde (qui produit des sorties entre 0 et 1) en dernière couche pour un problème de classification binaire, on utilisera généralement une entropie croisée binaire comme fonction de perte.
- Pour un problème de classification multi-classe, on utilise souvent la fonction softmax en dernière couche, qui produit une distribution de probabilités sur plusieurs classes. Dans ce cas, la fonction de perte associée est généralement l'entropie croisée catégorielle.
- Dans un problème de régression, on peut utiliser une fonction d'activation linéaire (sans transformation) et une fonction de perte comme l'erreur quadratique moyenne (MSE), car les valeurs de sortie ne sont pas limitées à un intervalle spécifique comme $[0,1]$.

Réseaux de neurones et Deep Learning


Tensorflow playground (again)



<https://playground.tensorflow.org>



Réseaux de neurones et Deep Learning

Deep versus shallow networks



Réseaux de neurones et Deep Learning

Qu'est-ce qu'un réseau de neurones ?




Réseaux de neurones et Deep Learning

Qu'est-ce qu'un réseau de neurones ?

Parlons succinctement de l'architecture d'un CNN.

Mots-clefs : backbone model, task head.



100	100	100	100	100
100	100	100	100	100
100	100	150	100	100
100	100	100	100	100
100	100	100	100	100

 $\ast$

0	-1	0
-1	5	-1
0	-1	0

 $=$



100	100	100	100	100
100	100	50	100	100
100	50	350	50	100
100	100	50	100	100
100	100	100	100	100



Complément sur les CNN


Réseaux de neurones et Deep Learning

Représentations internes au sein d'un réseau de neurones



Réseaux de neurones et Deep Learning

L'apprentissage d'un réseau de neurones : rétropropagation




Réseaux de neurones et Deep Learning

L'apprentissage d'un réseau de neurones : rétropropagation

Apprentissage d'un réseau de neurones = ajustement des poids des connexions entre les neurones pour minimiser l'erreur entre les prédictions du réseau et les valeurs réelles des données d'entraînement.

➡ Ce processus est généralement réalisé via des techniques d'optimisation telles que la rétropropagation combinée à des algorithmes de gradient, comme la descente de gradient stochastique.



Réseaux de neurones et Deep Learning

L'apprentissage d'un réseau de neurones : rétropropagation



Dans quelle direction aller ?




Doit-on faire des petits ou des grands pas ?

Réseaux de neurones et Deep Learning

L'apprentissage d'un réseau de neurones : rétropropagation


Optimisation par la dérivée/le gradient



$$x_{t+1} = x_t - \eta \times \nabla f(x_t)$$



Learning rate (taux d'apprentissage) :
détermine la vitesse de convergence



Réseaux de neurones et Deep Learning

L'apprentissage d'un réseau de neurones : rétropropagation

Rétropropagation de gradient

Formule(s) de rétropropagation :


$$\delta_j^k = \sum_{l=1}^{r^{k+1}} \delta_l^{k+1} w_{jl}^{k+1} g'(a_j^k) = g'(a_j^k) \sum_{l=1}^{r^{k+1}} w_{jl}^{k+1} \delta_l^{k+1}.$$

$$\frac{\partial E}{\partial w_{ij}^k} = \delta_j^k o_i^{k-1} = g'(a_j^k) o_i^{k-1} \sum_{l=1}^{r^{k+1}} w_{jl}^{k+1} \delta_l^{k+1}$$

Réseaux de neurones et Deep Learning

L'apprentissage d'un réseau de neurones : rétropropagation

Rétropropagation de gradient



Réseaux de neurones et Deep Learning

L'apprentissage d'un réseau de neurones : rétropropagation



La rétropropagation de gradient dans Tensorflow et Pytorch

- Dans TensorFlow et Pytorch, la rétropropagation est simplifiée grâce à une technique appelée **différentiation automatique**, qui calcule automatiquement les dérivées nécessaires à l'entraînement des réseaux de neurones. Si vous souhaitez aller plus loin, je vous conseille de vous renseigner à ce sujet.
- Les deux frameworks construisent un graphe computationnel représentant les opérations effectuées sur les tenseurs. Ce graphe est utilisé pour calculer automatiquement les dérivées de la perte par rapport à chaque paramètre du modèle, en appliquant la « règle de la chaîne » (dérivée d'une composée ou plutôt, pour les initiés, le théorème de Leibniz sur les dérivées partielles).
 - ➡ Dans TensorFlow, le module `tf.GradientTape` gère dynamiquement la création et l'utilisation de ce graphe pour le calcul des gradients. Ces gradients sont ensuite exploités par des optimiseurs comme `tf.keras.optimizers.Adam` pour ajuster les poids et les biais.
 - ➡ Dans PyTorch, un système similaire appelé Autograd crée un graphe computationnel dynamique pendant l'exécution. Les gradients sont calculés via un appel à `.backward()`.

Réseaux de neurones et Deep Learning


L'apprentissage d'un réseau de neurones : rétropropagation

Descente de gradient stochastique (SGD) / en mini-batch



Réseaux de neurones et Deep Learning



Généralisation des résultats d'un réseau de neurones



Réseaux de neurones et Deep Learning

Généralisation des résultats d'un réseau de neurones

Mais alors, si le calcul et la rétropropagation des gradients sont donnés par des formules déterministes et appliqués sur des batches du jeu d'entraînement, à quoi sert le jeu de validation ?



Réseaux de neurones et Deep Learning

Généralisation des résultats d'un réseau de neurones

Pratiques de conception

Complexité du modèle

Choisir une architecture de réseau (nombre de couches, nombre de neurones) appropriée à la complexité des données et à la taille de l'ensemble d'entraînement.

Optimisation des hyperparamètres

A l'aide de techniques comme le gridsearch ou la recherche bayésienne, trouver les hyperparamètres optimaux, y compris de l'optimizer (taux d'apprentissage, taux de régularisation...).

Ensembles de données adéquats

S'assurer que les ensembles de données utilisés pour l'entraînement, la validation et le test sont représentatifs du problème global que le modèle doit résoudre.

Réseaux de neurones et Deep Learning

Généralisation des résultats d'un réseau de neurones

Évaluation de la généralisation

Données de validation et de test

Séparer les données en ensembles d'entraînement, de validation et de test pour évaluer la performance du modèle de manière rigoureuse.

Courbes d'apprentissage

Tracer les courbes d'erreur pour les ensembles d'entraînement et de validation afin de visualiser le comportement du modèle et détecter le surapprentissage ou le sous-apprentissage.

Réseaux de neurones et Deep Learning

Généralisation des résultats d'un réseau de neurones

Techniques pour améliorer la généralisation

Régularisation

Ajout de pénalités (du type L1, L2) sur la taille des poids dans la fonction de perte pour encourager des poids plus petits et plus simples.

Dropout : désactivation aléatoire de neurones pendant l'entraînement pour éviter que le modèle ne devienne trop dépendant de certains neurones.

Early stopping

Arrêt de l'entraînement lorsque la performance sur les données de validation commence à se dégrader, empêchant ainsi le surapprentissage.

Augmentation de données

Création de nouvelles données d'entraînement en appliquant des transformations (rotations, translations, etc.) pour rendre le modèle plus robuste.

Cross validation

Utilisation de techniques de validation croisée (comme k-fold) pour évaluer la performance du modèle sur différents sous-ensembles des données, fournissant une estimation plus fiable de la capacité de généralisation.

Réseaux de neurones et Deep Learning

Optimisations et algorithmes de convergence

Synthèse à propos de la descente de gradient

- L'objectif de l'optimisation est de minimiser une fonction de coût (ou de perte) $L(\theta)$, où θ représente les paramètres du modèle.
- En ajustant les paramètres, le modèle est capable de mieux s'adapter aux données d'entraînement
- Les algorithmes d'optimisation sont basés sur le **gradient de la perte** par rapport aux paramètres du modèle.
- Principe :

$$\theta \leftarrow \theta - \eta \nabla_{\theta} L(\theta)$$

Réseaux de neurones et Deep Learning

Optimisations et algorithmes de convergence

Synthèse à propos de la descente de gradient

Variantes :

- **Batch Gradient Descent** : Utilise l'ensemble complet des données pour chaque mise à jour. Lent pour les grands ensembles de données.
- **Stochastic Gradient Descent (SGD)** : Met à jour les paramètres après chaque exemple de données. Plus rapide mais plus bruité.
- **Mini-Batch Gradient Descent** : Combine les deux approches, en utilisant des sous-ensembles des données pour chaque mise à jour.

Réseaux de neurones et Deep Learning

Optimisations et algorithmes de convergence

Algorithmes avec accélération

Les algorithmes modernes améliorent la convergence par des mécanismes comme le momentum, le découplage des gradients, ou des ajustements adaptatifs du taux d'apprentissage.

Momentum

Accélère l'optimisation en ajoutant une fraction de la mise à jour précédente :

$$\begin{aligned}v &\leftarrow \gamma v + \eta \nabla_{\theta} L(\theta) \\ \theta &\leftarrow \theta - v\end{aligned}$$

où γ est le coefficient de momentum.

Réseaux de neurones et Deep Learning

Optimisations et algorithmes de convergence

Algorithmes avec accélération

Les algorithmes modernes améliorent la convergence par des mécanismes comme le momentum, le découplage des gradients, ou des ajustements adaptatifs du taux d'apprentissage.

RMSProp

Ajuste le taux d'apprentissage en divisant par la moyenne pondérée des gradients au carré :

$$v_t \leftarrow \beta v_{t-1} + (1 - \beta)(\nabla_{\theta} L(\theta))^2$$
$$\theta \leftarrow \theta - \frac{\eta}{\sqrt{v_t} + \epsilon} \nabla_{\theta} L(\theta)$$

<https://www.digitalocean.com/community/tutorials/intro-to-optimization-momentum-rmsprop-adam>

Réseaux de neurones et Deep Learning

Optimisations et algorithmes de convergence

Algorithmes avec accélération

Les algorithmes modernes améliorent la convergence par des mécanismes comme le momentum, le découplage des gradients, ou des ajustements adaptatifs du taux d'apprentissage.

Adam (Adaptive moment estimation)

Combine le momentum et RMSProp pour ajuster le taux d'apprentissage :

$$\begin{aligned}m_t &= \beta_1 m_{t-1} + (1 - \beta_1) \nabla_{\theta} L(\theta) \\v_t &= \beta_2 v_{t-1} + (1 - \beta_2) (\nabla_{\theta} L(\theta))^2 \\ \theta &\leftarrow \theta - \frac{\eta}{\sqrt{\hat{v}_t} + \epsilon} \hat{m}_t\end{aligned}$$

où $\hat{m}_t$ et $\hat{v}_t$ sont des versions corrigées des biais.

<https://medium.com/analytics-vidhya/a-complete-guide-to-adam-and-rmsprop-optimizer-75f4502d83be>

Réseaux de neurones et Deep Learning

Optimisations et algorithmes de convergence

Problèmes courants et solutions

Taux d'apprentissage inapproprié

Si le taux d'apprentissage est trop grand, l'optimisation diverge. Si le taux est trop petit, la convergence est lente.

Solution : Utiliser des algorithmes adaptatifs (Adam, RMSProp) ou un scheduler.

Convergence vers des minima locaux

Les fonctions de perte complexes peuvent avoir plusieurs minima.

Solution : Utiliser des techniques comme le momentum ou des algorithmes adaptatifs pour éviter les plateaux et minima locaux.

Problème de vanishing/exploding gradients

Les gradients deviennent très petits (vanishing) ou très grands (exploding), rendant l'apprentissage inefficace.

Solution : Normalisation des données, initialisation appropriée des poids, ou utilisation de fonctions d'activation spécifiques.

Réseaux de neurones et Deep Learning

Optimisations et algorithmes de convergence

Mesures pour accélérer la convergence

Taux d'apprentissage adaptatif Diminue le taux d'apprentissage au fur et à mesure de l'entraînement (scheduler ou annealing).

Batch normalization Normalise les activations des couches pour stabiliser l'apprentissage.

Early stopping Arrête l'entraînement lorsqu'il n'y a plus d'amélioration sur un ensemble de validation.

Régularisation Empêche le surapprentissage en ajoutant des pénalités sur les poids (L1, L2) ou en utilisant des techniques comme le dropout.

Réseaux de neurones et Deep Learning

Initialisations et régularisations d'un réseau de neurones

L'initialisation des poids et les techniques de régularisation jouent un rôle clé pour garantir que les réseaux de neurones **convergent correctement** et **généralisent bien** aux données non vues.

Pourquoi l'initialisation est importante ?

Accélérer la convergence : une initialisation correcte permet un entraînement plus rapide en réduisant les oscillations. En particulier, au-delà de l'intuition « si on part de plus loin, on va mettre plus de temps à arriver », un enjeu est d'**éviter la disparition/explosion des gradients** : si les poids sont mal initialisés (par exemple, trop grands ou trop petits), les gradients aux-mêmes peuvent devenir trop petits (vanishing gradient) ou trop grands (exploding gradient).

Réseaux de neurones et Deep Learning

Initialisations et régularisations d'un réseau de neurones

Techniques courantes d'initialisation

Initialisation aléatoire uniforme/gaussienne

Les poids sont initialisés à partir d'une distribution uniforme ou normale.

Limitation : Peut conduire à des gradients instables.

Initialisation Xavier/Glorot

Pour les activations linéaires ou sigmoïdes.

Distribue les poids de manière à ce que la variance des activations soit stable entre les couches.

$$W \sim U \left(-\frac{\sqrt{6}}{\sqrt{n_{in} + n_{out}}}, \frac{\sqrt{6}}{\sqrt{n_{in} + n_{out}}} \right)$$

Initialisation He

Optimisée pour les activations ReLU ou variantes.

$$W \sim \mathcal{N} \left(0, \frac{2}{n_{in}} \right)$$

Initialisation LeCun

Optimisée pour les activations comme tanh.

$$W \sim \mathcal{N} \left(0, \frac{1}{n_{in}} \right)$$

Réseaux de neurones et Deep Learning

Initialisations et régularisations d'un réseau de neurones

Régularisation L1 et L2

$$\mathcal{L}_1 = \mathcal{L}_{\text{original}} + \lambda \sum |W|$$

$$\mathcal{L}_2 = \mathcal{L}_{\text{original}} + \frac{\lambda}{2} \sum W^2$$

L2 tend à réduire la magnitude des poids de manière globale.

L1 force certains poids à devenir exactement nuls (sparse).



```
from tensorflow.keras.regularizers import l2
layer = Dense(64, activation='relu', kernel_regularizer=l2(0.01))
```



Réseaux de neurones et Deep Learning

Initialisations et régularisations d'un réseau de neurones

Dropout

Désactive aléatoirement une proportion de neurones pendant l'entraînement pour éviter la co-dépendance entre neurones.

Efficace pour réduire le surapprentissage.



```
from tensorflow.keras.layers import Dropout  
model.add(Dropout(0.5))
```

Réseaux de neurones et Deep Learning

Initialisations et régularisations d'un réseau de neurones

Batch normalization

- Normalise les activations de chaque couche pour maintenir une distribution stable.
- Ajoute un recalibrage (scale et shift) via des paramètres apprenables (γ et β).
- Appliqué après la couche précédente mais avant l'activation.

$$\hat{x}_i = \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}}$$

- μ_B : Moyenne du mini-batch
- σ_B^2 : Variance du mini-batch
- ϵ : Petite constante pour éviter la division par zéro

$$y_i = \gamma \hat{x}_i + \beta$$

- γ : Paramètre d'échelle (appris pendant l'entraînement)
- β : Paramètre de décalage (appris pendant l'entraînement)



```
from tensorflow.keras.layers import BatchNormalization
model.add(Dense(64, activation='relu'))
model.add(BatchNormalization())
```

Réseaux de neurones et Deep Learning

Initialisations et régularisations d'un réseau de neurones

Les objectifs d'une batch normalization

- Réduire le "Internal Covariate Shift"
- Accélérer la convergence :
- Réduire la sensibilité à l'initialisation des poids
- Agir comme un régularisateur

➡ En réalité, les apports de cette technique sont surtout constatés empiriquement.

Réseaux de neurones et Deep Learning

Initialisations et régularisations d'un réseau de neurones

Méthode	Réduction du surapprentissage	Impact sur l'entraînement	Cas d'usage
Régularisation L1/L2	Moyen - Élevé	Peu perturbant	Contrôle direct sur les poids
Dropout	Élevé	Ajoute du bruit	Réseaux denses et convolutionnels
Batch normalization	Faible - Moyen	Améliore la stabilité	Réseaux profonds avec un apprentissage long

Réseaux de neurones et Deep Learning

Data Augmentation : comment équilibrer un dataset ?

L'équilibrage d'un dataset dans le cadre des réseaux de neurones à l'aide de la Data Augmentation est une stratégie couramment utilisée pour améliorer les performances d'un modèle. Plus généralement, la Data Augmentation s'avère particulièrement utile dans plusieurs cas de figure :

- ➡ Lorsque le **dataset** est **trop petit** pour permettre un entraînement efficace du modèle.
- ➡ Lorsque des **variations** peuvent **légitimement** survenir (par exemple, dans des tâches de traitement d'images, des perturbations comme des décalages de l'objet ou du système d'acquisition).
- ➡ Lorsque certaines classes sont sur-représentées par rapport à d'autres dans le jeu de données (« **déséquilibre des classes** »), ce qui peut biaiser le modèle.



Réseaux de neurones et Deep Learning

Data Augmentation : comment équilibrer un dataset ?

Le déséquilibre des classes

Un dataset est déséquilibré lorsqu'une ou plusieurs classes ont beaucoup plus d'exemples que les autres. Cela peut conduire un modèle à biaiser les prédictions vers la classe majoritaire/ignorer les classes minoritaires, ce qui affecte les performances globales.

L'objectif est alors d'équilibrer le dataset pour que le modèle apprenne efficacement de toutes les classes.

La Data Augmentation consiste à générer de nouvelles données à partir des données existantes pour compenser le manque d'exemples dans les classes minoritaires.


Réseaux de neurones et Deep Learning

Data Augmentation : comment équilibrer un dataset ?

Oversampling des classes minoritaires

But : générer de nouvelles données synthétiques ou augmentées pour les classes minoritaires jusqu'à atteindre un équilibre.

- **Transformations géométriques**
(rotation, flip, zoom, recadrage, translation)
- **Modification des couleurs**
(ajustement de la luminosité, du contraste, ou de la saturation)
- **Ajout de bruit** (bruit gaussien ou salt-and-pepper)
- Techniques avancées : CutMix, MixUp, ou CutOut pour mélanger ou masquer des parties d'images.



Synonymie,
paraphrase,
ajout/suppression de mots...



Jittering (ajout de bruit),
Time Warping (déformation
temporelle).

Il est également possible d'utiliser des modèles comme les GANs (Generative Adversarial Networks) pour générer de nouvelles données proches des données existantes.

Réseaux de neurones et Deep Learning

Data Augmentation : comment équilibrer un dataset ?

Oversampling des classes minoritaires



```
from tensorflow.keras.preprocessing.image import ImageDataGenerator

datagen = ImageDataGenerator(
    rotation_range=20,
    width_shift_range=0.2,
    height_shift_range=0.2,
    shear_range=0.2,
    zoom_range=0.2,
    horizontal_flip=True,
    fill_mode='nearest'
)

minority_class_images = [...] # images de classe minoritaire
augmented_images = []
for img in minority_class_images:
    img = img.reshape((1,) + img.shape) # redim. pour le générateur
    for batch in datagen.flow(img, batch_size=1):
        augmented_images.append(batch[0])
        if len(augmented_images) >= TARGET_NUMBER:
            break
```



```
import torch
import torchvision.transforms as transforms
from PIL import Image
import numpy as np

augmentation_transforms = transforms.Compose([
    transforms.RandomRotation(20),
    transforms.RandomAffine(0, translate=(0.2, 0.2)),
    transforms.RandomAffine(0, shear=20),
    transforms.RandomResizedCrop(size=(224, 224), scale=(0.8, 1.2)),
    transforms.RandomHorizontalFlip(),
    transforms.ToTensor(),
])

minority_class_images = [...] # images de classe minoritaire
augmented_images = []
for img in minority_class_images:
    img = Image.fromarray(img)
    for _ in range(TARGET_NUMBER // len(minority_class_images)):
        augmented_img = augmentation_transforms(img)
        augmented_images.append(augmented_img)

augmented_images = torch.stack(augmented_images)
```

Réseaux de neurones et Deep Learning

Data Augmentation : comment équilibrer un dataset ?

Undersampling des classes majoritaires

But : réduire le nombre d'exemples dans les classes majoritaires pour équilibrer le dataset.

Avantages

Réduit le temps d'entraînement, minimise le risque de biais introduit par la création d'exemples artificiels, et évite les risques de fuite d'information (*data leakage*) souvent associés à l'oversampling.

Inconvénients

Risque de perdre des informations importantes sur les classes majoritaires.

➡ Cette méthode peut être combinée avec l'oversampling pour éviter une perte excessive d'information.

Réseaux de neurones et Deep Learning

Data Augmentation : comment équilibrer un dataset ?

Techniques basées sur les poids des classes

Principe : modifier la fonction de perte pour accorder plus d'importance aux classes minoritaires.

Par exemple, dans le cas de la cross-entropy :

$$\text{Loss} = -\frac{1}{N} \sum_{i=1}^N w_c \cdot y_i \log(\hat{y}_i)$$

où w_c est un poids plus élevé pour les classes minoritaires.

Utiliser la syntaxe native des bibliothèques pour cela :

- `torch.nn.CrossEntropyLoss(weight=class_weights)` en PyTorch
- le paramètre `class_weight` dans TensorFlow/Keras.

Ces techniques permettent au modèle de traiter le déséquilibre sans modifier le dataset lui-même, et sont de mon point de vue à privilégier lorsqu'on cherche à régler un pur déséquilibre.

Réseaux de neurones et Deep Learning

Data Augmentation : comment équilibrer un dataset ?

Techniques basées sur les poids des classes

Autre exemple avec la focal loss :

$$\text{Focal Loss} = -(1 - \hat{y})^\gamma \cdot y \log(\hat{y})$$

avec γ ajustant l'importance des erreurs/des exemples bien classés.

De manière générale, on utilise des variantes de la fonction de perte pour accorder plus d'attention aux exemples « difficiles »/« importants » (en cas de déséquilibre de classes, mais également en cas de déséquilibre de coût métier de l'erreur selon les classes).

Réseaux de neurones et Deep Learning

Data Augmentation : comment équilibrer un dataset ?

Techniques basées sur les poids des classes

Enfin, dans le cadre spécifique des réseaux de neurones, il est possible de faire du **batch balancing**.

Idée : construire des mini-batches équilibrés en sélectionnant un nombre égal d'exemples pour chaque classe.

Cela garantit que chaque batch représente correctement la distribution équilibrée des classes.

Réseaux de neurones et Deep Learning

Data Augmentation : comment équilibrer un dataset ?

Techniques basées sur les poids des classes



```
import tensorflow as tf
import numpy as np

class_counts = [500, 150, 50] # exemple de distribution
class_weights = {i: 1.0 / count for i, count in enumerate(class_counts)}

# Créer le modèle, le compiler, préparer les données...
...

# Entraînement avec class_weight
model.fit(x_train, y_train, epochs=10, class_weight=class_weights)
```

```
import torch
import torch.nn as nn

class_counts = [500, 150, 50] # exemple de distribution
class_weights = [1.0 / count for count in class_counts]
weights = torch.FloatTensor(class_weights)

# Appliquer les poids dans la fonction de perte
criterion = nn.CrossEntropyLoss(weight=weights)
```

03

Applications du Deep Learning

Applications du Deep Learning



Révolution du deep learning : généricité des outils et des problématiques



Applications du Deep Learning

Différents scénarios : donnée tabulaire, texte, image, son (le retour)

Texte – Transformers, BERT



Applications du Deep Learning

Différents scénarios : donnée tabulaire, texte, image, son (le retour)

Texte – Sentence embedding

	Time	Mood	Outdoors
1 Good morning!	2	8	4
2 I hate Mondays	2	1	1
3 This park is awesome!	3	9	8
4 This is too much, I need coffee	7	3	2
5 It's great to be out here	3	8	8

Exemple : **USE** (Universal Sentence Encoder) de Google.

2 versions principales : Transformer et DAN (Deep Averaging Network)

Transformer : Repose sur l'architecture des transformers, qui est conçue pour capturer les relations contextuelles entre les mots dans une séquence. Utilise le mécanisme d'attention pour peser l'importance des mots contextuels lors de la création des embeddings de phrases.

DAN : Repose sur un réseau de neurones profond qui prend en compte la moyenne des embeddings de mots pondérés pour générer l'embedding de la phrase. Utilise des méthodes d'apprentissage non supervisées pour apprendre des représentations de phrases informatives.

Applications du Deep Learning

Génération de texte

I love eating

prompt


bagels with cream cheese
my mother's meatloaf
out with friends

AI output

Applications du Deep Learning

Génération d'images par Neural Style Transfer

content image



Ancient city of Persepolis

+

style image



The Starry Night (Van Gogh)

=

generated image



Persepolis
in Van Gogh style

Applications du Deep Learning

Génération d'images par Neural Style Transfer



Activité :

<https://www.neuralframes.com/tools/ai-style-transfer>

Applications du Deep Learning

Génération d'images à partir d'un texte

A beautiful, pastoral mountain scene.
Landscape painting style (Midjourney)



Two cute kittens playing (DALL-E)



Applications du Deep Learning

Génération d'images à partir d'un texte

Algorithmes de diffusion



Image 1



Image 2




Image 3



Image 4

Entrée

Image bruitée



Sortie

**Image légèrement
moins bruitée**

Entrée	Sortie
Image 2	Image 1
Image 3	Image 2
Image 4	Image 3

Applications du Deep Learning

Génération d'images à partir d'un texte

Algorithmes de diffusion




Image 1

Entrée



Sortie



Applications du Deep Learning

Génération d'images à partir d'un texte

Algorithmes de diffusion



Image 1




Image 2

Entrée



Sortie



Applications du Deep Learning

Génération d'images à partir d'un texte

Algorithmes de diffusion



Image 1




Image 2





Image 3

Entrée



Sortie



Applications du Deep Learning

Génération d'images à partir d'un texte

Algorithmes de diffusion



Image 1




Image 2




Image 3




Image 4

~100 étapes

Applications du Deep Learning

Génération d'images à partir d'un texte

Algorithmes de diffusion : ajout d'un texte



Image 1,
« pomme rouge »



Image 2




Image 3




Image 4

Entrée

Image bruitée



Sortie

**Image légèrement
moins bruitée**

Entrée	Sortie
Image 2, « pomme rouge »	Image 1
Image 3, « pomme rouge »	Image 2
Image 4, « pomme rouge »	Image 3

Applications du Deep Learning

Génération d'images à partir d'un texte

Algorithmes de diffusion : ajout d'un texte



Image 1

Entrée



+ « **banane verte** »



Sortie



Applications du Deep Learning

Génération d'images à partir d'un texte

Algorithmes de diffusion : ajout d'un texte



Image 1



Image 2

Entrée



+ « **banane verte** »



Sortie



Applications du Deep Learning

Génération d'images à partir d'un texte

Algorithmes de diffusion : ajout d'un texte



Image 1



Image 2



Image 3


Entrée



+ « **banane verte** »



Sortie



Applications du Deep Learning

Génération d'images à partir d'un texte

Algorithmes de diffusion : ajout d'un texte



Image 1



Image 2



Image 3




Image 4


Applications du Deep Learning

Jeux vidéos



Applications du Deep Learning

Text to materials



Applications du Deep Learning

Cas d'usage implémenté



Démonstration :
Classification d'images météo

07

Les outils (spoiler) – outils de haut niveaux

Les outils

L'aide à la rédaction : amélioration de texte, génération automatique de texte...

Amélioration de texte

- Correction grammaticale et orthographique
- Réécriture et reformulation
- Optimisation stylistique



Génération automatique de texte

- Rédaction de contenu automatisée
- Réponses automatiques
- Création de brouillons



Recherche et synthèse d'informations

- Résumés automatiques
- Compilation et agrégation de contenu

Personnalisation du contenu

- Adaptation du texte au lecteur et création de contenu ciblé



ChatGPT

Les outils

L'aide à la rédaction : amélioration de texte, génération automatique de texte...


Model	Lab	Playground	Parameters (B)	Tokens trained (B)	Ratio Tokens:Params (Chinchilla scaling ≥20)	ALScore "ALScore" Sqr Root of Any ALSc	MMLU -Pro	MMLU GPQA	Training cost
Olympus	Amazon	https://lifearchitect.ai	2000	40000					
GPT-5	OpenAI	https://lifearchitect.ai	52500						
GPT-6	OpenAI	https://lifearchitect.ai							
AuroraGPT (Scienc	Argonne National	https://lifearchitect.ai	1000	30000					
MAI-1	Microsoft	https://arstechnica.com	500	10000	20:1	7.5			
Grok-3	xAI	https://lifearchitect.ai/grok/							
SFR-LLaMA-3.1-7	Salesforce	https://blog.salesforce.com	70	15000	215:1	3.4			W 📖 ⬆ 🏠
AMD-Llama-135m	AMD	https://huggingface.co	0.135	670	4,963:1	0.0	23.02		📖 🧑 🏠
Llama 3.2 90B	Meta AI	https://www.llama.co	90	9000	100:1	3.0			W 📖 ⬆ 🏠
Llama 3.2 3B	Meta AI	https://www.llama.co	3.21	9000	2,804:1	0.6	63.4	32.8	W 📖 ⬆ 🏠
Molmo	Allen AI	https://molmo.allenai.org	72	7000	98:1	2.4			W 📖 ⬆ 🏠
Gemini-1.5-Pro-00	Google DeepMind	https://aistudio.google.com	1500	30000	20:1	22.4		75.8 59.1	W 📖 ⬆ 🏠
Qwen2.5	Alibaba	https://huggingface.co	72	18000	250:1	3.8	86.1	71.1 49	W 📖 ⬆ 🏠
GRIN MoE	Microsoft	https://huggingface.co	60	4025	68:1	1.6	79.4		🧠
Data-Gemma	Google DeepMind	https://huggingface.co	27	13000	482:1	2.0			W 📖 ⬆ 🏠
o1	OpenAI	https://chatgpt.com/					92.3	91 78.3	W 📖 ⬆ 🏠
Reader-LM	Jina AI	https://huggingface.co	1.54	2.5	2:1	0.0			🏠
Pixtral-12b-240910	Mistral	https://huggingface.co	12	6000	500:1	0.9	69.2		W 📖 ⬆ 🏠

Source : <https://lifearchitect.ai/models-table/>

Les outils

L'aide à la rédaction : amélioration de texte, génération automatique de texte...

Quelques défis



Qualité des textes générés



Originalité et créativité

Les outils

L'aide au brainstorming

- Génération d'idées (exploration de nouvelles pistes, inspiration par association d'idées...)
- Recommandations basées sur des données (suggestions personnalisées, analyse prédictive, recommandations à partir d'études comparatives)
- Approfondissement des idées
- Organisation et structuration des idées (mind mapping, clustering...)
- Stimulation de la créativité (notamment grâce à des connaissances multidisciplinaires)
- Soutien au travail collaboratif

Les outils

Génération de média

Création automatique d'images

- Génération d'images à partir de texte
- Synthèse d'images réalistes
- Personnalisation et variations

Création automatique de vidéos

- Montage vidéo intelligent
- Génération de vidéos à partir de texte
- Vidéo en motion capture



Les outils

Génération de média... au-delà d'une utilisation personnelle

Retouches et manipulation d'images

- Amélioration d'images
- Retouches automatiques
- Deepfakes



Création et manipulation d'environnements virtuels (modélisation 3D, génération de paysages)

Automatisation des effets spéciaux (VFX)

Génération automatique de musique et de bande sonore

- Création de musique par IA
- Sound design

Personnalisation et adaptation des contenus (de la personnalisation des médias à l'adaptation en temps réel)

04

Quels problèmes peut-on résoudre avec le Machine Learning et avec le Deep Learning ?

Quels problèmes peut-on résoudre avec le ML et le DL ?

Introduction

A peu près tous les problèmes, pour peu qu'il y ait les données pour (ou qu'il existe déjà un modèle tout fait qui fasse le travail).

Quels problèmes peut-on résoudre avec le ML et le DL ?

Quand ne (peut-être) pas utiliser l'IA (1/2)

- Lorsqu'un bon vieux système de règles convient très bien.
- Lorsque je n'ai pas d'historique de données suffisamment volumineux ou de suffisamment bonne qualité (dans ce cas la mise en place de l'IA peut se faire une fois ce problème réglé).
- Lorsque les décisions attendues sont sensiblement morales ou éthiques.
- Lorsque la confidentialité des données et de la vie privée n'est pas garantie/que les risques de fuite ou de mauvaise gestion sont trop élevés.
- Lorsque cela risque de conduire à un remplacement d'humains problématique (aide, plus grande valeur ajoutée vs simple remplacement, en particulier dans les métiers où l'empathie est cruciale).

Quels problèmes peut-on résoudre avec le ML et le DL ?

Quand ne (peut-être) pas utiliser l'IA (2/2)

- Lorsque l'explicabilité du modèle n'atteint pas le degré d'interprétation souhaité (santé mais aussi justice ou finance).
- Lorsque se posent des problèmes de biais (provenant essentiellement des données d'entraînement).
- En cas de dérive trop difficile à gérer (covariate, target, concept, domain).
- Lorsque le cadre législatif est incertain.

Quels problèmes peut-on résoudre avec le ML et le DL ?

Idéation de cas d'usage



Etude de cas :

**Données touristiques - candidature
d'une métropole comme capitale
européenne de la culture**

Quels problèmes peut-on résoudre avec le ML et le DL ?

Données brutes versus features

- **Feature creation**

Cette étape consiste à **identifier les variables les plus utiles** à utiliser dans un modèle prédictif. Ce processus subjectif nécessite une intervention humaine, plus ou moins créative, et souvent liée à une connaissance *métier*. Les nouvelles caractéristiques sont créées en combinant les caractéristiques existantes (additions, soustractions, ratios, lag features...) et offrent une grande flexibilité.

- **Feature transformation**

L'amélioration de la précision d'un modèle passe souvent par l'ajustement des variables prédictives. Il est fréquent que les modèles aient à traiter une grande variété de distributions de données en entrée. Pour certains modèles, il faut veiller à ce que toutes les variables soient à une **échelle** comparable ; dans certains cas, **transformer une distribution** vers une allure plus gaussienne augmentera les performances.

- **Feature extraction**

L'extraction de caractéristiques est un processus automatisé qui **génère de nouvelles variables, sous forme numérique, en les extrayant à partir des données brutes** (en particulier des textes et des images). L'objectif principal de cette étape est de réduire le volume de données pour qu'il puisse être facilement utilisé et géré pour la modélisation. Les méthodes d'extraction de caractéristiques incluent l'analyse de cluster, l'analyse de texte, les algorithmes de détection de contours, l'analyse en composantes principales (ACP)....

- **Feature selection**

Il arrive qu'uniquement une partie des variables du jeu de données soit utile pour construire notre modèle. Tant pour des raisons de temps de calcul que de performance, il est très important d'**identifier et de sélectionner les variables les plus appropriées dans les données**, en supprimant les caractéristiques redondantes, non pertinentes ou bruitées.

Quels problèmes peut-on résoudre avec le ML et le DL ?

Cas d'usage en vrac

Donnée	Sortie	Cas d'usage / secteur
Email	Spam ? (0/1)	Filtre automatique de spams
Publicité, utilisateur	Clic futur ? (0/1)	Publicité en ligne ciblée
Flux d'images acquises par une caméra/un radar de voiture	Position des autres véhicules	Véhicules autonomes
Radiographie	Diagnostic médical	Santé
Image d'un matériel	Défaillant ? (0/1)	Inspection visuelle
Enregistrement audio	Transcription textuelle	Reconnaissance vocale
Avis d'utilisateurs	Sentiment (positif/négatif)	Gestion de la satisfaction client

Quels problèmes peut-on résoudre avec le ML et le DL ?

Conditions sur les données



Volumétrie



Dimensionnement



Equilibre entre les classes



Description

L'IA au service des départements d'une organisation


Vente

L'IA permet d'optimiser les ventes en fournissant des **analyses prédictives** pour anticiper les tendances, des **recommandations personnalisées** de produits et des stratégies de vente sur mesure, améliorant ainsi les conversions et la satisfaction client.



L'IA au service des départements d'une organisation

Marketing



Grâce à l'IA, les entreprises peuvent **analyser** de grandes quantités de données, effectuer une **segmentation** précise des audiences et **personnaliser** leurs campagnes, tout en **générant du contenu automatiquement**, ce qui accroît leur portée et impact.

L'IA au service des départements d'une organisation

Management

L'IA facilite la **prise de décisions stratégiques** en aidant les managers à mieux **gérer** les ressources, **identifier** les opportunités d'amélioration et **optimiser** la planification des activités à l'échelle de l'entreprise.



L'IA au service des départements d'une organisation

Finance




Dans le domaine financier, l'IA **automatise** les processus comptables, réduisant ainsi les erreurs humaines, tout en permettant des **prévisions** financières plus précises pour mieux anticiper les besoins en trésorerie ou les **risques** financiers.

L'IA au service des départements d'une organisation

Ressources humaines

L'IA améliore le recrutement en **analysant les données des candidats**, facilitant la présélection et la gestion des talents, tout en optimisant les processus RH tels que la **gestion des performances** ou la **rétection** des employés.



L'IA au service des départements d'une organisation

Service client



Les chatbots et assistants virtuels alimentés par l'IA fournissent une **assistance instantanée** et **personnalisée**, tandis que l'**analyse des sentiments** permet de mieux comprendre les émotions des clients et d'adapter l'expérience en conséquence.

L'IA au service des départements d'une organisation

Transversal

L'IA permet d'**automatiser** de nombreuses tâches administratives, libérant ainsi du temps pour les employés et réduisant les coûts, tout en garantissant des **processus** plus fluides et rapides à travers toute l'organisation.

Complément

Aspects éthiques et juridiques liés à l'Intelligence Artificielle

Aspects éthiques et juridiques liés à l'Intelligence Artificielle

CNIL : mission et évolution

Créée en 1978, c'est une autorité administrative indépendante en France chargée de protéger les données personnelles et de **garantir le respect de la vie privée des citoyens**. Sa mission principale est de veiller à ce que la collecte, le traitement et la gestion des données personnelles par les organisations, qu'elles soient publiques ou privées, respectent les droits et les libertés individuelles.



Mission 1 : Informer, protéger les droits

Mission 2 : Accompagner la conformité / conseiller


Mission 3 : Anticiper et innover

Mission 4 : Contrôler et sanctionner

Dans l'ensemble, la CNIL existe et évolue pour répondre aux défis posés par la numérisation croissante de la société et pour renforcer la protection des données personnelles des citoyens français dans un environnement en constante évolution.

Aspects éthiques et juridiques liés à l'Intelligence Artificielle

Droit d'accès aux données personnelles



Aspects éthiques et juridiques liés à l'Intelligence Artificielle

Droit d'accès aux données personnelles

La question de- l'accès aux données personnelles et de leur traitement passe par plusieurs piliers, autour desquels est articulé la réglementation de référence sur le sujet : le RGPD.

- **Principe de transparence** : Les organisations doivent informer de manière claire et concise les individus sur la manière dont leurs données personnelles seront collectées, utilisées et traitées. Les politiques de confidentialité doivent être faciles à comprendre et accessibles.
- **Droit à l'information et au consentement** : Les individus ont le droit d'être informés de manière transparente sur la collecte de leurs données, et ils doivent donner leur consentement explicite pour que leurs données soient traitées. Ils ont également le droit de retirer leur consentement à tout moment.
- **Droit d'accès** : Les individus ont le droit d'accéder aux données personnelles que les organisations détiennent à leur sujet. Ils peuvent demander des informations sur la finalité du traitement, les catégories de données traitées et les destinataires des données.
- **Droit à la portabilité** : Les individus ont le droit de recevoir leurs données personnelles dans un format structuré et couramment utilisé, et ils peuvent les transférer d'une organisation à une autre.
- **Droit de rectification** : Les individus ont le droit de demander la correction de données personnelles inexactes ou incomplètes.

Aspects éthiques et juridiques liés à l'Intelligence Artificielle

Droit d'accès aux données personnelles

- **Droit à l'oubli** : Également connu sous le nom de droit à l'effacement, ce droit permet aux individus de demander la suppression de leurs données personnelles lorsque celles-ci ne sont plus nécessaires à la finalité pour laquelle elles ont été collectées.
- **Principe de minimisation des données** : Les organisations doivent collecter uniquement les données personnelles nécessaires à la finalité pour laquelle elles sont traitées et doivent limiter la quantité de données collectées.
- **Principe de protection des données par défaut (« Privacy by Design »)** : Les organisations doivent intégrer la protection des données dès la conception de leurs systèmes et services, en tenant compte de la confidentialité dès le début du processus.
- **Responsabilité et obligations des responsables de traitement et des sous-traitants** : Les organisations doivent mettre en place des politiques internes pour assurer la conformité au RGPD. Les sous-traitants sont également tenus de respecter les règles de protection des données.
- **Notification des violations de données** : Les organisations sont tenues de signaler les violations de données personnelles à l'autorité de protection des données dans les 72 heures suivant leur découverte, à moins que la violation ne présente pas de risque pour les droits et libertés des individus.
- **Responsabilité et amendes** : Le RGPD prévoit des sanctions financières sévères en cas de non-conformité, pouvant atteindre jusqu'à 4 % du chiffre d'affaires annuel mondial de l'entreprise contrevenante.

Aspects éthiques et juridiques liés à l'Intelligence Artificielle

Droit d'accès aux données personnelles

La **durée de conservation des données**, le **lieu d'hébergement** des données et la **sécurité** des données sont des aspects essentiels de la gestion des données, en particulier dans le contexte de la protection de la vie privée et de la conformité aux réglementations.

Durée de conservation des données

La durée de conservation des données se réfère à la période pendant laquelle les données personnelles ou professionnelles sont stockées avant d'être détruites ou supprimées.

Elle peut varier en fonction de la nature des données, de la finalité de leur collecte et des exigences légales.

Certains types de données peuvent nécessiter une conservation à long terme pour se conformer à la loi, tandis que d'autres peuvent être supprimés une fois qu'ils ne sont plus nécessaires.

Aspects éthiques et juridiques liés à l'Intelligence Artificielle

Droit d'accès aux données personnelles

Lieu d'hébergement des données

Le lieu d'hébergement des données se réfère à l'emplacement physique ou virtuel où les données sont stockées.

Le choix du lieu d'hébergement est important car il peut avoir des implications sur la sécurité, la confidentialité et la conformité réglementaire.

Certaines réglementations, telles que le RGPD, imposent des restrictions sur le transfert international de données personnelles en dehors de l'UE, exigeant que ces transferts respectent certaines conditions.

Sécurité des données

La sécurité des données englobe un large éventail de pratiques, de mesures et de technologies visant à protéger les données contre les menaces telles que les cyberattaques, les violations de données et les accès non autorisés.

Cela comprend l'authentification, l'autorisation, le chiffrement, la surveillance des menaces, la gestion des vulnérabilités, etc.

La sécurité des données est cruciale pour prévenir les fuites de données et les violations de la vie privée.

Aspects éthiques et juridiques liés à l'Intelligence Artificielle

Propriété intellectuelle des algorithmes

La question de la propriété intellectuelle des algorithmes est un sujet complexe et en constante évolution. Elle se situe à l'intersection du droit de la propriété intellectuelle, de la technologie et du commerce.

- **Brevetabilité des algorithmes** : Dans de nombreuses juridictions, les algorithmes en tant que tels ne sont pas brevetables. Cependant, des méthodes ou des processus basés sur des algorithmes peuvent être brevetés si elles satisfont aux critères de brevetabilité, tels que l'originalité, la nouveauté et l'applicabilité industrielle. L'office européen des brevets a estimé que, lorsqu'un algorithme est intégré au sein d'une invention brevetable, celui-ci peut bénéficier de la protection du droit des brevets à condition qu'il contribue au « caractère technique de la méthode » brevetée.
- **Droit d'auteur** : Les algorithmes peuvent être protégés par le droit d'auteur s'ils sont considérés comme des œuvres originales de création. Cependant, la protection du droit d'auteur ne couvre généralement que l'expression écrite de l'algorithme (le code source), pas l'algorithme lui-même.
- **Secrets commerciaux** : De nombreuses entreprises considèrent leurs algorithmes comme des secrets commerciaux précieux et les protègent en gardant le code source confidentiel. Cela peut être renforcé par des accords de confidentialité avec les employés et les sous-traitants.


Aspects éthiques et juridiques liés à l'Intelligence Artificielle

Propriété intellectuelle des algorithmes

- **Licences et open source** : Certains algorithmes sont mis à disposition sous licence ou en tant que logiciels open source. Dans ce cas, les créateurs peuvent permettre à d'autres de les utiliser, de les modifier et de les distribuer sous certaines conditions spécifiées dans la licence.
- **Responsabilité et éthique** : L'utilisation d'algorithmes soulève également des questions de responsabilité et d'éthique. Les créateurs d'algorithmes doivent considérer les implications éthiques de leur utilisation, en particulier dans des domaines sensibles comme l'intelligence artificielle et l'apprentissage automatique.
- **Collaboration et partage** : De nombreuses avancées dans le domaine de la technologie reposent sur la collaboration et le partage d'algorithmes. Les chercheurs et les développeurs peuvent collaborer sur des projets open source ou partager des algorithmes pour promouvoir l'innovation.

Aspects éthiques et juridiques liés à l'Intelligence Artificielle

AI Act



Aspects éthiques et juridiques liés à l'Intelligence Artificielle

AI Act

	FOURNISSEUR	DÉPLOYEUR	MANDATAIRE	IMPORTATEUR	DISTRIBUTEUR
Définition	personne physique ou morale, autorité publique, agence ou tout autre organisme qui		personne physique ou morale située ou établie dans l'Union qui		personne physique ou morale
	développe ou fait développer un SIA ou un GPAI et le met sur le marché ou met le SIA en service sous son propre nom ou sa propre marque, à titre onéreux ou gratuit	Utilise sous sa propre autorité un SIA sauf lorsque ce système est utilisé dans le cadre d'une activité personnelle à caractère non professionnel	a reçu et accepté un mandat écrit d'un fournisseur de SIA ou de GPAI pour s'acquitter en son nom des obligations et des procédures établies par le présent règlement	met sur le marché un SIA qui porte le nom ou la marque d'une personne physique ou morale établie dans un pays tiers	faisant partie de la chaîne d'approvisionnement, autre que le fournisseur ou l'importateur, qui met un SI à disposition sur le marché de l'Union
Risque inacceptable	/	/	/	/	/
Haut-risque	Obligations pour les fournisseurs d'IA à haut risque	Obligations pour les déployeurs d'IA à haut risque	Obligations pour les mandataires d'IA à haut risque	Obligations pour les importateurs d'IA à haut risque	Obligations pour les distributeurs d'IA à haut risque
Risque limité	Obligations pour les fournisseurs d'IA à risque soumis à obligations de transparence	Obligations pour les déployeurs d'IA à risque soumis à obligations de transparence	Aucune obligation	Aucune obligation	Aucune obligation
Risque minimal	Code de bonnes pratiques - volontaire	Code de bonnes pratiques - volontaire	Code de bonnes pratiques - volontaire	Code de bonnes pratiques - volontaire	Code de bonnes pratiques - volontaire

Aspects éthiques et juridiques liés à l’Intelligence Artificielle

AI Act - risque inacceptable

Typologie	Description
Technique subliminale	Tout système ou partie de système visant influencer subliminalement le public.
Exploitation de personnes vulnérables	Tout système ou partie de système visant influencer une population vulnérable (handicape, âge, situation sociale ou économique) grâce à la dite vulnérabilité.
Catégorisation biométrique	Tout système ou partie de système visant à catégoriser une population en fonction de ses attributs biométriques que cela soit au niveau de sa race, ses opinions politiques ou son appartenance à un syndicats, un courant politique ou religieux.
Score social	Système évaluant des personnes physiques en fonction de leur comportement social, ou de leurs caractéristiques personnelles ou de personnalité connues, déduites ou prédites.
Identification biométrique à distance "en temps réel"	Tout système permettant de suivre, repérer, identifier des personnes physiques dans un espace public et cela en temps réel pour l’administration (sauf lorsque c’est strictement nécessaire).
Création de bases de données de visage	Systèmes qui créent ou développent des bases de données de reconnaissance faciale par l'extraction non ciblée d'images faciales sur l'internet ou d'images de vidéosurveillance.
Analyse de sentiment	Système qui permet de déduire les émotions d'une personne physique sur le lieu de travail et dans les établissements d'enseignement.
225 Prédiction d’infraction pénale	Système ayant pour but d'évaluer ou de prédire le risque qu'une personne physique commette une infraction pénale, sur la seule base de son profilage ou de l'évaluation de ses traits de personnalité et de ses caractéristiques.

Aspects éthiques et juridiques liés à l'Intelligence Artificielle

AI Act – secteur de la Défense



DÉFENSE ET SÉCURITÉ

- **Hors champ** si SIA à usage militaire/défense ou sécurité nationale pur
- **Haut risque** si usage de gestion de la sécurité publique (vidéosurveillance, cybersécurité civile, reconnaissance faciale, surveillance publique)
- (SIA utilisé par des organes civils ou en appui à la sécurité publique -> annexes I ou III)

Aspects éthiques et juridiques liés à l'Intelligence Artificielle

Impartialité des algorithmes

L'impartialité des algorithmes, souvent liée au concept de biais algorithmique, est une préoccupation croissante dans le domaine de la data science et de l'intelligence artificielle. Nous pourrions croire qu'en déportant un processus dans un traitement algorithmique automatisé, le résultat s'en retrouve non biaisé. Mais en réalité, les algorithmes, lorsqu'ils sont formés sur des données historiques, peuvent hériter des biais présents dans ces données, ce qui peut entraîner des résultats inéquitables ou discriminatoires.

Cela fait écho aux questions de l'**IA de confiance**.

Pour aller plus loin : différence entre biais éthique et biais algorithmique.

Aspects éthiques et juridiques liés à l'Intelligence Artificielle

Impartialité des algorithmes : impact sur le traitement des données et la modélisation

Collecte de données biaisées : Les données utilisées pour former des modèles d'apprentissage automatique peuvent refléter des biais historiques, sociaux ou culturels. Par exemple, si un système de recrutement est formé sur des données de CV historiques qui favorisent les candidats masculins, le modèle peut être biaisé en faveur des hommes.

Prétraitement des données : Il est important de prétraiter les données pour atténuer les biais potentiels. Cela peut inclure l'équilibrage des données pour garantir une représentation égale de toutes les catégories, la suppression des caractéristiques fortement biaisées, ou la collecte de données plus diversifiées.

Choix de l'algorithme : Certains algorithmes sont plus sensibles aux biais que d'autres. Le choix de l'algorithme dépendra du type de données et des objectifs du modèle. Certains modèles, comme les forêts aléatoires, sont moins sensibles aux données biaisées que d'autres, comme les réseaux de neurones.

Aspects éthiques et juridiques liés à l'Intelligence Artificielle

Impartialité des algorithmes et quelques éléments en lien avec l'IA de confiance

Évaluation de l'équité : Des mesures d'équité doivent être définies pour évaluer les performances d'un modèle du point de vue de l'impartialité. Ces mesures peuvent inclure la disparité d'impact, la disparité de traitement, ou la perte d'utilité équitable.

Correction des biais : Des techniques existent pour corriger les biais dans les modèles. Cela peut inclure l'ajout de poids aux exemples sous-représentés, la réévaluation des caractéristiques utilisées pour la prise de décision, ou la génération de données synthétiques.

Transparence et explicabilité : Il est important que les modèles soient transparents et explicables afin que les décideurs puissent comprendre comment les décisions sont prises. Cela permet également de détecter et de corriger les biais plus facilement.

Surveillance continue : Les systèmes basés sur l'IA doivent faire l'objet d'une surveillance continue pour détecter les biais qui pourraient émerger avec de nouvelles données ou de nouveaux comportements.

Aspects éthiques et juridiques liés à l'Intelligence Artificielle

Biais de confirmation

Le biais de confirmation est un phénomène cognitif humain qui se produit lorsque nous accordons une plus grande attention aux informations qui confirment nos croyances préexistantes, tout en ignorant ou minimisant les informations qui les contredisent.

Aspects éthiques et juridiques liés à l'Intelligence Artificielle

Biais de confirmation

Le biais de confirmation va se retrouver en machine learning :

Biais dans les données d'entraînement : (rappel) si les données d'entraînement utilisées pour former un modèle contiennent des biais, le modèle apprendra à reproduire ces biais. Par exemple, si un algorithme d'embauche est formé sur des données historiques qui ont favorisé les candidats masculins, le modèle peut également montrer une préférence pour les candidats masculins.

Renforcement des stéréotypes : les modèles d'apprentissage automatique peuvent involontairement renforcer des stéréotypes existants en tirant des conclusions basées sur des corrélations dans les données. Par exemple, un modèle de recommandation de contenu pourrait recommander des vidéos similaires à celles déjà visionnées, ce qui pourrait renforcer les préférences existantes de l'utilisateur.

Effet de filtre de bulle : les systèmes de recommandation, notamment sur les réseaux sociaux et les plateformes de streaming, peuvent créer un "effet de filtre de bulle" en exposant les utilisateurs à un contenu qui confirme leurs opinions existantes, les isolant ainsi des perspectives alternatives.

Exercice de l'esprit critique devant les sorties des algorithmes : Nous avons tendance à croire de manière démesurée les sorties des algorithmes alors même qu'ils sont souvent accompagnés d'un effet « black box ».

Aspects éthiques et juridiques liés à l'Intelligence Artificielle

Biais de confirmation

On va donc chercher à atténuer le biais de confirmation dans le machine learning, à travers certaines actions.

Collecte de données équilibrées : S'assurer que les données d'entraînement sont équilibrées et représentent de manière équitable toutes les catégories ou groupes d'intérêt, plutôt que de privilégier un groupe spécifique.

Prétraitement des données : Examiner et prétraiter les données pour détecter et corriger les biais potentiels. Cela peut inclure la suppression de caractéristiques fortement biaisées ou la réévaluation des étiquettes.


Utilisation de modèles équitables : Certains modèles d'apprentissage automatique sont conçus pour être plus équitables et moins sensibles aux biais. Ces modèles peuvent être préférables dans des domaines sensibles.

Transparence et interprétabilité : Assurer la transparence et l'interprétabilité des modèles afin de comprendre comment ils prennent des décisions, ce qui facilite la détection et la correction des biais.

Surveillance continue : Mettre en place des mécanismes de surveillance continue pour détecter et atténuer les biais émergents à mesure que de nouvelles données sont collectées.

Aspects éthiques et juridiques liés à l'Intelligence Artificielle

Evaluation des LLMs



Aspects éthiques et juridiques liés à l'Intelligence Artificielle

Réflexion sur les enjeux sociétaux et éthiques liés à l'IA



Réflexion collective :
Ethique et IA

Aspects éthiques et juridiques liés à l'Intelligence Artificielle

Réflexion sur les enjeux sociétaux et éthiques liés à l'IA

1. Comment évaluez-vous l'importance relative de l'IA par rapport à d'autres **enjeux sociétaux** tels que le réchauffement climatique, la pauvreté, l'accès à l'éducation, la santé, la sécurité alimentaire, la géopolitique mondiale ou la crise migratoire ?
2. Comment l'IA peut-elle **contribuer positivement** à résoudre les défis sociétaux cruciaux tels que le réchauffement climatique, la pauvreté, l'accès à l'éducation, la santé, la sécurité alimentaire, la géopolitique mondiale ou la crise migratoire ?
3. Comment évaluez-vous la **menace** potentielle de l'IA **sur la société**, notamment en ce qui concerne la protection des données personnelles, la manipulation de l'opinion publique ou la désinformation, la surveillance de masse, la déshumanisation du travail... ?
4. Dans quelle mesure l'impact négatif potentiel de l'IA couplé à la difficulté de comprendre le fonctionnement précis des systèmes à base d'IA vous préoccupe-t-il ?
5. Si tous les avènements semblent être plus ou moins possibles, comment voyez-vous l'impact de l'IA le plus probable sur ces thématiques ?

Aspects éthiques et juridiques liés à l'Intelligence Artificielle

Réflexion sur les enjeux sociétaux et éthiques liés à l'IA

6. Comment jugez-vous l'impact de l'IA sur les entreprises et les acteurs des **secteurs d'activité en dehors de l'IA** ?
7. La **consommation en énergie** des systèmes à base d'IA peut-elle être problématique ? Si oui, comment répondre à cela et faut-il le faire de manière spécifique à l'IA, ou avec des mesures plus globales qui appartiennent au marché de l'énergie ?
8. Comment percevez-vous l'**évolution des attentes et des besoins** en matière d'IA ?
9. Pour les acteurs autres que les **géants de l'IA** disposant de ressources considérables, est-il toujours pertinent d'investir des efforts dans le développement de nouveaux modèles et algorithmes d'IA de pointe, ou est-il plus important d'utiliser efficacement les modèles existants publiés par ces acteurs majeurs ? Si la seconde option est celle préférable d'un point de vue pratique, cette situation est-elle problématique ?
10. Comment percevez-vous la **collaboration entre les différentes entreprises** et organisations travaillant sur l'IA ?
11. Comment évaluez-vous le **rythme de développement** de l'IA par rapport à vos éventuelles attentes au cours des deux dernières décennies (plus rapide, plus lent, conforme) ?


05

Préparation d'un dataset

Préparation d'un dataset

Qu'est-ce qu'un dataset ?

Kaggle : plus de 50 000 jeux de données et 400 000 notebooks publics.




<https://www.kaggle.com/datasets/netflix-inc/netflix-prize-data>

Préparation d'un dataset

Qu'est-ce qu'un dataset ?

Le jeu de données **ImageNet** est incontestablement l'un des ensembles de données les plus influents et révolutionnaires dans le domaine de la vision par ordinateur et de l'apprentissage automatique. Composé de millions d'images de haute résolution, ImageNet couvre une vaste gamme de catégories d'objets et de scènes. Ce jeu de données a été à l'origine introduit pour la compétition annuelle "ImageNet Large Scale Visual Recognition Challenge", qui a contribué de manière significative à faire progresser la recherche en apprentissage profond et en reconnaissance d'images.



Préparation d'un dataset

Qu'est-ce qu'un dataset ?

- ImageNet a été rendu particulièrement précieux par son échelle massive et la diversité de ses images. Il a été le catalyseur de nombreuses percées dans les **réseaux de neurones convolutionnels** (CNN) et a contribué à la montée en puissance de l'apprentissage profond. Il a également mis en évidence l'importance de la pré-formation des réseaux neuronaux sur de grandes quantités de données avant de les adapter à des tâches spécifiques.
- ImageNet a ouvert la voie à des applications de **reconnaissance d'objets**, **détection d'objets**, de **segmentation sémantique** et même de **génération d'images** réalistes par des réseaux génératifs adverses (GAN). Il a grandement stimulé la collaboration au sein de la communauté de la vision par ordinateur et continue de jouer un rôle essentiel dans l'évolution de l'intelligence artificielle.
- Il est par exemple possible de télécharger ce jeu de données à l'adresse <https://www.image-net.org/download.php>

Préparation d'un dataset

Qu'est-ce qu'un dataset ?

- **CIFAR-10 et CIFAR-100** : Contiennent des images en couleur de 32x32 pixels réparties en 10 ou 100 classes différentes, respectivement. Ils sont utilisés pour la classification d'images et l'apprentissage de la vision par ordinateur.
- **COCO (Common Objects in Context)** : Contient des images complexes avec des objets dans leur contexte. Il est utilisé pour la détection d'objets, la segmentation sémantique et d'autres tâches de vision par ordinateur.
- **PASCAL VOC** : Contient des images annotées avec des objets appartenant à 20 catégories différentes. Il est utilisé pour l'évaluation d'algorithmes de détection d'objets et de segmentation sémantique.
- **CelebA** : Visages de célébrités avec des annotations pour des attributs faciaux tels que la présence de lunettes, le sourire, etc. Il est utilisé pour la reconnaissance faciale et d'autres tâches liées aux visages.


Préparation d'un dataset

Qu'est-ce qu'un dataset ?

- **LFW (Labeled Faces in the Wild)** : Visages de personnes célèbres également. Il est couramment utilisé pour les tâches de vérification de visages, où l'objectif est de déterminer si deux images de visages appartiennent à la même personne.
- **Cityscapes** : Images de scènes urbaines avec des annotations de segmentation sémantique, ce qui en fait une ressource précieuse pour la compréhension des environnements urbains par les ordinateurs.
- **MURA** : Données médicales qui contient des radiographies pour la détection de fractures. Il est utilisé pour la télémédecine et la classification d'images médicales.
- **Fashion MNIST** : Contient des images de vêtements et d'accessoires. Il est utilisé pour la classification d'images de produits et de mode. Inspiré par MNIST.

Préparation d'un dataset


Stocker, contrôler, nettoyer et convertir la donnée



Préparation d'un dataset

Stocker, contrôler, nettoyer et convertir la donnée

Données quantitatives et qualitatives



Préparation d'un dataset

Stocker, contrôler, nettoyer et convertir la donnée

Données quantitatives

- Les variables **quantitatives** représentent des **mesures numériques** qui ont une signification mathématique, et permettent de réaliser des **opérations** également **mathématiques** telles que l'addition, la soustraction, la multiplication et la division.
- Ces variables fournissent une base pour effectuer des **analyses statistiques** approfondies, calculer des moyennes, des écarts-types et identifier des **relations numériques entre les données**.
- L'ensemble des valeurs possibles est parfois **continu** dans l'idée (généralement à valeurs réelles) tandis qu'il sera **discret** dans d'autres situations (décimaux, souvent entiers...). Les comportements sont similaires, mais il peut par exemple être plus confortable de discrétiser les valeurs obtenues par régression lorsque la variable est supposée être discrète (ex. : pour estimer ma prochaine note en mathématiques, je vais probablement arrondir ma prédiction au point près/au demi-point près/au quart de point près/au centième près).
- Parfois considérées comme à part, ou quantitatives mais particulières, certaines données peuvent être placées sur un **axe ordonné** et **combinées**, mais **selon un sous-ensemble d'opérations**, qui perdent en outre leur caractère « interne ». C'est notamment le cas pour les informations de dates (time series) : il est possible de les ranger, il est impossible de les multiplier, il est possible de les soustraire mais on obtient alors une durée et non une date. Les durées sont quant à elles classiquement quantitatives.

Préparation d'un dataset

Stocker, contrôler, nettoyer et convertir la donnée

Données qualitatives

- Les variables **qualitatives** représentent des caractéristiques non numériques qui décrivent des **catégories** ou des **groupes distincts**.
- Elles sont souvent utilisées pour classer ou regrouper des données en fonction de caractéristiques spécifiques, telles que le genre, la couleur, la région géographique...
- Les variables qualitatives ne peuvent pas être soumises à des opérations mathématiques standard, mais elles jouent un rôle crucial dans l'analyse des tendances et des modèles au sein de différents groupes.

➡ **Au sein des variables qualitatives, une caractéristique essentielle à bien prendre en compte est la présence ou non d'une relation d'ordre sur les valeurs.** La possibilité de hiérarchiser les valeurs a un impact considérable sur la manière de les traiter et de les modéliser.

Couleur
Rouge
Jaune
Bleu
Marron
Vert

Avis client
Très satisfait
Satisfait
Moyennement satisfait
Peu satisfait
Totalement insatisfait

Préparation d'un dataset

Stocker, contrôler, nettoyer et convertir la donnée

➡ A noter qu'il existe un ensemble particulier de valeurs qualitatives, très répandu : celui des variables binaires.

Statut marital
Marié
Non Marié
Marié
Non Marié



Marié
1
0
1
0

A décroché
Oui
Non
Non
Oui



A décroché
1
0
0
1

Préparation d'un dataset

Stocker, contrôler, nettoyer et convertir la donnée

Traitement des valeurs manquantes

- Le traitement des valeurs manquantes occupe une place cruciale dans le domaine du Machine Learning, car des données incomplètes peuvent avoir un impact significatif sur la qualité des modèles, voire les rendre inutilisables.
- Différentes techniques existent pour gérer ce problème.
- La **quantité** de valeurs manquantes et la compréhension de la **raison** au manque entrent en compte dans le choix de la technique appliquée.

Les familles de techniques employées sont :

- ➡ dans le cas de *fausses* valeurs manquantes, le **remplacement par la valeur attendue** (0, chaîne de caractère vide),
- ➡ la **suppression** de données (lignes ou colonnes),
- ➡ l'**imputation simple**, par exemple par la moyenne ou la médiane (pour les données numériques) ou le mode (pour les données numériques ou catégorielles),
- ➡ l'**imputation avancée**, basée sur des modèles d'imputation.

A noter que certains modèles prennent en charge la présence de valeurs manquantes (k-NN, naive Bayes...) de façon native, mais il est classique de rendre systématique le traitement de ces valeurs manquantes.

Préparation d'un dataset

Stocker, contrôler, nettoyer et convertir la donnée

Traitement des valeurs manquantes


Certaines valeurs sont très « particulières » vis-à-vis de la distribution de données : elles sont atypiques. Il s'agit d'un argument **statistique**. La majorité des méthodes de détection sont de type **quartiles** ou **écart-type**.

Certaines valeurs posent problème vis-à-vis de notre connaissance de la variable représentée : elles sont aberrantes. Il s'agit d'un argument **métier**.

La plupart des valeurs aberrantes sont atypiques (mais pas toujours en cas de problème systématique).

Sucre pour 100g	Gras pour 100 g
0	20
33	113
70	60
-18	3
21	68

Âge (ans)
31
147
23
41
37




Préparation d'un dataset

Stocker, contrôler, nettoyer et convertir la donnée

Autres nettoyages

Certaines formes de données peuvent demander une préparation plus poussée et plus spécifique. C'est par exemple le cas des données textuelles.

Dans ce cas, les problèmes de qualité peuvent être nombreux (orthographe, casse, espaces et caractères spéciaux...) et laborieux à régler du fait de la complexité intrinsèque de la langue.



Préparation d'un dataset

Stocker, contrôler, nettoyer et convertir la donnée


Zoom sur l'encoding

Un modèle de Machine Learning est une gigantesque **fonction mathématique** définie uniquement sur des **valeurs numériques en entrée**. Il est donc nécessaire de **convertir en nombres** (« code/encoder ») toutes les **entrées non numériques**.



Préparation d'un dataset

Stocker, contrôler, nettoyer et convertir la donnée




Comment encoderiez-vous les éléments suivants ?

Avis
Non satisfait
Peu satisfait
Moyennement satisfait
Satisfait
Très satisfait

Adresse	Prix (k€)
10 rue de la Paix	3 300
150 avenue des Champs Elysées	2 500
338 avenue des Champs Elysées	2 100
37 avenue des Champs Elysées	3 500
12 place Pigalle	1 600
51 place Pigalle	1 900

Préparation d'un dataset

Stocker, contrôler, nettoyer et convertir la donnée



>>> Label Encoding



On remplace la variable de départ par une valeur numérique comprise entre 1 et le nombre de catégories différentes (ou 0 et le nombre moins 1).



On l'applique la plupart du temps lorsque les catégories sont "ordonnées" par nature (pour éviter d'introduire artificiellement une hiérarchie là où il n'y en a pas).




Pour cette raison on l'appelle aussi parfois ordinal encoding.

Avis	Code assigné
Non satisfait	0
Peu satisfait	1
Moyennement satisfait	2
Satisfait	3
Très satisfait	4

Préparation d'un dataset

Stocker, contrôler, nettoyer et convertir la donnée





>>> One-hot Encoding



On crée une nouvelle colonne pour chaque valeur/catégorie possible, avec un codage binaire (0 ou 1) pour indiquer à quelle catégorie chaque ligne appartient. L'expression « one hot » vient du fait qu'il y aura un seul 1 par ligne.

C'est un encoding très utilisé pour des variables catégorielles non ordonnées qui n'admettent pas beaucoup de valeurs possibles. Si une variable a 30 valeurs différentes, cet encodage nécessitera 30 nouvelles colonnes.

Le risque est d'obtenir des données trop "creuses" (avec beaucoup de 0) et de se heurter à un problème de dimension. Cela peut impacter à la fois le temps de calcul des ordinateurs et les performances des modèles, du fait de certaines propriétés mathématiques des espaces à grande dimension (la "malédiction de la dimensionnalité").




Mais nous avons vu quelques techniques pour diminuer (raisonnablement) cette dimension !


Adresse	Adresse Paix	Adresse Champs	Adresse Pigalle	Adresse Courcelles	Adresse Foch
10 rue de la Paix	1	0	0	0	0
150 avenue des Champs Elysées	0	1	0	0	0
12 place Pigalle	0	0	1	0	0
43 boulevard de Courcelles	0	0	0	1	0
32 avenue Foch	0	0	0	0	1

Préparation d'un dataset

Stocker, contrôler, nettoyer et convertir la donnée



>>> Target Encoding



C'est une technique d'encodage dite "bayésienne" : elle utilise les informations de la variable cible ("target") à prédire pour coder les données catégorielles. Nous calculons la moyenne de la variable cible pour chaque catégorie et remplaçons la variable catégorie par la valeur moyenne.

Adresse	Prix (k€)
10 rue de la Paix	3 300
150 avenue des Champs Elysées	2 500
338 avenue des Champs Elysées	2 100
37 avenue des Champs Elysées	3 500
12 place Pigalle	1 600
51 place Pigalle	1 900



Rue	Code assigné
Rue de la Paix	3 300
Avenue des Champs Elysées	2 700
Place Pigalle	1 750



On perd un petit peu en information mais c'est la technique à utiliser pour encoder des variables non ordonnées avec beaucoup de valeurs possibles !

Préparation d'un dataset

Stocker, contrôler, nettoyer et convertir la donnée

Scaling

Le scaling (**mise à l'échelle**) est une étape essentielle dans le prétraitement des données avant de les utiliser dans des algorithmes d'apprentissage automatique. Il vise à standardiser ou à normaliser les valeurs de différentes caractéristiques (variables) pour les rendre comparables et cohérentes. L'importance du scaling réside dans le fait que de nombreux algorithmes fonctionnent en se basant sur des **mesures de distance**, de similitude ou de norme entre les données. Si les variables ont des échelles différentes, cela peut entraîner des distorsions dans les calculs et une mauvaise convergence des algorithmes.

Préparation d'un dataset

Stocker, contrôler, nettoyer et convertir la donnée


Scaling

#	Emp	Age	Salary
1	Emp1	44	73000
2	Emp2	27	47000
3	Emp3	30	53000
4	Emp4	38	62000
5	Emp5	40	57000
6	Emp6	35	53000
7	Emp7	48	78000

Distance between Emp2 and Emp1 = $\sqrt{(27 - 44)^2 + (47000 - 73000)^2} = 31.06$

Distance between Emp2 and Emp3 = $\sqrt{(30 - 27)^2 + (53000 - 47000)^2} = 6.70$

$$\text{Euclidean Distance } d = \sqrt{(a_2 - a_1)^2 + (b_2 - b_1)^2}$$



Préparation d'un dataset

Stocker, contrôler, nettoyer et convertir la donnée

Scaling

$$x_{\text{norm}} = \frac{x - \min(x)}{\max(x) - \min(x)}$$

#	Emp	Age	Salary
1	Emp1	44	73000
2	Emp2	27	47000
3	Emp3	30	53000
4	Emp4	38	62000
5	Emp5	40	57000
6	Emp6	35	53000
7	Emp7	48	78000

Normalization



Age	Normalized Age	Salary	Normalized Salary
44	0.80952381	73000	0.838709677
27	0	47000	0
30	0.142857143	53000	0.193548387
38	0.523809524	62000	0.483870968
40	0.619047619	57000	0.322580645
35	0.380952381	53000	0.193548387
48	1	78000	1

Range 0-1


Range 0-1

How to calculate Normalized value?
X = 35, min = 27, max = 48 for column Age.
$$x_{\text{norm}}(\text{for } 35) = \frac{35 - 27}{48 - 27} = 0.3809$$

Préparation d'un dataset

Stocker, contrôler, nettoyer et convertir la donnée

Scaling



Préparation d'un dataset

Stocker, contrôler, nettoyer et convertir la donnée

Scaling

Exemples d'algorithmes qui utilisent la notion de distance/norme et qui bénéficient du scaling :

K-Means : Cet algorithme de clustering calcule les distances entre les points pour les attribuer à des clusters. Si les variables ne sont pas mises à l'échelle, celles avec des échelles plus grandes auront un impact disproportionné sur les calculs de distance, conduisant à des résultats biaisés.

Méthodes basées sur les voisins : Des algorithmes tels que k-NN (k plus proches voisins) utilisent également des distances pour déterminer les voisins les plus proches. Si les variables ne sont pas mises à l'échelle, certaines variables peuvent dominer les calculs de distance, affectant ainsi les prédictions.

Machines à vecteurs de support (SVM) : Les SVM cherchent à maximiser la marge entre les classes en se basant sur les distances entre les points de données et les hyperplans de séparation. Le scaling est crucial ici pour éviter que des variables à grande échelle dominent celles à petite échelle.

Préparation d'un dataset

Stocker, contrôler, nettoyer et convertir la donnée

Scaling

Exemples d'algorithmes qui ne nécessitent pas nécessairement de scaling en raison de leur nature intrinsèque ou de leur façon de traiter les données :

Arbres de décision et forêts aléatoires : Les arbres de décision divisent les données en fonction des valeurs de variables, indépendamment de leur échelle. Les forêts aléatoires agrègent plusieurs arbres, ce qui réduit également la sensibilité à l'échelle.




Méthodes basées sur les règles : Les méthodes comme les règles d'association (par exemple, Apriori) se concentrent sur la présence ou l'absence de valeurs plutôt que sur leurs échelles.

Réseaux de neurones profonds : Les réseaux de neurones profonds, en particulier les architectures modernes comme les transformeurs, sont capables d'apprendre des relations complexes même avec des variables à différentes échelles. Cependant, le scaling peut accélérer la convergence.

Préparation d'un dataset

Comprendre la donnée


Quel est l'intérêt d'une étude multidimensionnelle ?



Préparation d'un dataset

Comprendre la donnée

- Identifier les relations entre différentes variables permet de comprendre les liens sous-jacents et les influences mutuelles qui peuvent exister dans un ensemble de données. Ces corrélations peuvent révéler des tendances, des dépendances et des interactions qui aident à prendre des décisions éclairées et à formuler des hypothèses.
- Pour mener ces études, divers outils **statistiques** sont utilisés, tels que le coefficient de corrélation de Pearson pour mesurer la force et la direction de la relation linéaire entre deux variables continues, ou le test du chi carré pour explorer les associations entre des variables catégorielles.
- Les **graphiques**, tels que les diagrammes de dispersion et les matrices de corrélation, fournissent également des moyens visuels pour appréhender les relations entre les données.
- En combinant ces outils avec une compréhension approfondie du contexte et du domaine d'étude, l'analyse des corrélations offre des perspectives précieuses pour mieux appréhender les complexités et les interconnexions au sein des données. Cela est utile pour **préparer les données** ainsi que pour analyser certains comportements émergents plus finement et gagner en **perspective métier** grâce aux statistiques.




Matrice de corrélation

Préparation d'un dataset

Comprendre la donnée

Causalité, corrélation et colinéarité



Multicolinéarité : Existence de liens entre les colonnes/variables sous forme de combinaisons linéaires.



Exemple des attaques de requin et ventes de glaces.


Préparation d'un dataset

Comprendre la donnée


Réduction de dimension > ACP

L'ACP a deux objectifs principaux. Elle permet d'étudier :

- ➡ la **variabilité entre les individus** : quelles sont les différences et les ressemblances entre individus ?
- ➡ les **liaisons entre les variables** : y a-t-il des groupes de variables très corrélées entre elles, qui peuvent être regroupées en de nouvelles variables synthétiques ?



Il y a des projections pour lesquelles on voit moins bien que d'autres, avec lesquelles on perd plus d'information que d'autres (exemple du cinéma).




Préparation d'un dataset

Comprendre la donnée


Réduction de dimension > ACP

Mots-clefs

Espaces vectoriels normés, réduction d'endomorphismes, sous-espaces propres, matrice de covariance, axes d'inertie.



Nuage des individus





Nuage des variables

Préparation d'un dataset

Comprendre la donnée

Réduction de dimension > ACP




Plan factoriel et cercle des corrélations

Préparation d'un dataset

Comprendre la donnée

Réduction de dimension > ACP



Eboulis des valeurs propres

Préparation d'un dataset

Jeu d'entraînement, jeu de validation, jeu de test

Le découpage des données en ensembles d'entraînement, de validation et de test (« split train-validation-test ») est une pratique courante en apprentissage automatique pour évaluer et ajuster la performance des modèles de manière rigoureuse.

Cette approche vise à garantir que le modèle est capable de généraliser correctement sur de nouvelles données et à éviter le surajustement (overfitting) aux données d'entraînement



Préparation d'un dataset

Jeu d'entraînement, jeu de validation, jeu de test


Train : **Pour entraîner le modèle.** Le modèle apprend les relations entre les caractéristiques (variables indépendantes) et la variable cible en utilisant ces données. L'objectif est de permettre au modèle de capturer les modèles et les structures présents dans les données d'entraînement.

Validation : **Pour régler les hyperparamètres du modèle et évaluer sa performance pendant le processus d'entraînement.** Les hyperparamètres sont les paramètres du modèle qui ne sont pas appris à partir des données, tels que la taille du lot (batch size), le taux d'apprentissage, la profondeur d'un arbre, etc. En utilisant le jeu de validation, vous pouvez ajuster ces hyperparamètres pour obtenir les meilleures performances sur des données non vues.

Test : **Pour évaluer la performance finale et la capacité de généralisation du modèle.** Ces données n'ont pas été utilisées pendant l'entraînement ou le réglage des hyperparamètres. En évaluant le modèle sur des données inconnues, vous obtenez une estimation réaliste de sa performance en conditions réelles.

Préparation d'un dataset

Jeu d'entraînement, jeu de validation, jeu de test




Préparation d'un dataset

Jeu d'entraînement, jeu de validation, jeu de test

Validation croisée

La validation croisée est une méthodologie essentielle en apprentissage automatique pour évaluer la performance des modèles de manière plus fiable et robuste. Elle vise à surmonter les limitations potentielles de la simple division des données en ensembles d'entraînement et de test en réalisant des **évaluations multiples** et en utilisant **l'ensemble des données disponibles** de manière plus efficace.

La validation croisée implique la séparation des données en plusieurs sous-ensembles, également appelés "**plis**". Le processus est généralement décomposé en plusieurs **itérations**. **À chaque itération, un pli est retenu comme ensemble de test et les autres plis sont utilisés comme ensemble d'entraînement.** Le modèle est alors formé et évalué sur le pli de test. Ce processus est répété pour chaque pli, de sorte que chaque pli sert successivement de jeu de test.



Préparation d'un dataset

Jeu d'entraînement, jeu de validation, jeu de test

Validation croisée

L'un des avantages clés de la validation croisée est qu'elle permet d'utiliser l'ensemble complet des données à la fois pour l'entraînement et l'évaluation. Cela réduit le risque d'une évaluation biaisée due à la division arbitraire des données. En moyennant les performances sur plusieurs plis, la validation croisée fournit une estimation plus **stable** et **réaliste** de la performance du modèle.

La validation croisée est particulièrement utile **lorsque les données d'entraînement sont limitées**. Elle permet d'utiliser chaque point de données pour l'entraînement et la validation à un moment donné. De plus, elle permet de mieux évaluer la capacité de généralisation du modèle, car il est testé sur des données qu'il n'a pas vues pendant l'entraînement.

Il existe plusieurs méthodes de validation croisée, dont la validation croisée en **k-folds** et la validation croisée **stratifiée** (non exclusives). Dans la validation croisée en k-folds, les données sont divisées en k plis et chaque pli sert une fois de jeu de test. Dans la validation croisée stratifiée, la répartition des classes dans chaque pli est maintenue pour éviter tout biais.

Préparation d'un dataset

Mettre en place une structure d'évaluation des algorithmes

1. Définition des objectifs

But de l'algorithme	Définir clairement l'objectif principal que l'algorithme doit atteindre.
Critères de réussite	Déterminer les indicateurs de performance clés (KPIs) pour évaluer le succès de l'algorithme.

2. Recherche et Sélection des Algorithmes

Revue de littérature	Effectuer une recherche exhaustive des algorithmes existants dans le domaine pertinent.
Sélection préliminaire	Sélectionner les algorithmes potentiellement pertinents basés sur des critères définis (complexité, performance, adaptabilité).

3. Validation Théorique

Analyse comparative	Comparer les algorithmes sélectionnés sur des aspects théoriques tels que l'efficacité computationnelle, la scalabilité et la robustesse.
Propriétés	Vérifier les propriétés théoriques des algorithmes (convergence, optimalité...).

Préparation d'un dataset

Mettre en place une structure d'évaluation des algorithmes

4. Implémentation et tests initiaux

Prototype

Implémenter des prototypes des algorithmes sélectionnés.

Données exemples

Tester les algorithmes sur des jeux de données simulés ou synthétiques pour vérifier leur comportement de base.

5. Évaluation empirique

Métriques

Définir des métriques claires pour évaluer la performance (temps de calcul, précision, rappel, F1-score, etc.).

Données réelles

Tester les algorithmes sur des jeux de données réels et variés pour évaluer leur performance dans des conditions pratiques.

6. Comparaison et analyse des résultats

Benchmarking

Comparer les résultats obtenus avec les différents algorithmes en utilisant les métriques de performance.

Analyse statistique

Utiliser des techniques statistiques pour déterminer la pertinence et la significativité des différences observées.

7. Sélection et Optimisation

Algorithme optimal

Sélectionner l'algorithme qui offre les meilleures performances globales.

Optimisation

Optimiser les paramètres de l'algorithme sélectionné pour maximiser ses performances.

Préparation d'un dataset

Mettre en place une structure d'évaluation des algorithmes

8. Documentation et transparence

Documentation détaillée

Documenter chaque étape du processus, les décisions prises, les résultats obtenus, et les justifications des choix effectués.

Reproductibilité

S'assurer que les résultats sont reproductibles en fournissant un code clair et bien commenté, ainsi que les jeux de données utilisés.

9. Revue par les pairs et feedback

Revue par les pairs

Faire examiner le processus et les résultats par des experts indépendants pour obtenir des avis critiques et des suggestions d'amélioration.

Incorporation du feedback

Intégrer les retours reçus pour affiner l'algorithme et le processus de validation.

10. Déploiement et surveillance continue

Déploiement

Mettre en production l'algorithme sélectionné.

Surveillance

Mettre en place des mécanismes de surveillance continue pour détecter toute dégradation de la performance et ajuster l'algorithme en conséquence.

06

Recherche de la solution optimale


Recherche de la solution optimale

Guide pour le décideur/pilote

Phase 1 :



Phase 2 :



Recherche de la solution optimale

La question de l'alignement



*Source de l'image :
les Echos*

https://fr.wikipedia.org/wiki/Alignement_des_intelligences_artificielles

Recherche de la solution optimale

Choix d'une direction de recherche

- **Publications** en lien avec le sujet (articles scientifiques, tutoriels)
- **Projets** similaires, y compris en interne !
- **Modèles** correspondants pertinents



Recherche de la solution optimale

Choix d'une direction de recherche



Hugging Face

<https://huggingface.co/models?sort=trending>


Recherche de la solution optimale

Méthodologie ML/DL

- **Typologie du problème**
- **Besoin métier** et ses caractéristiques
- **Caractéristiques du jeu de données** (ex. : volume)
- **Niveau de performance cible**
- **Contraintes supplémentaires** (gestion souhaitée des valeurs manquantes, temps d'inférence limite, explicabilité...)


Recherche de la solution optimale

Méthodologie ML/DL



Modèle simple

VS





Modèle compliqué

Recherche de la solution optimale

Méthodologie ML/DL

Recherche d'hyperparamètres



Recherche de la solution optimale

Cas de l'IA générative

Construire une solution d'IA générative est un processus très empirique.

- Modèles pré-entraînés
 - Fine tuning
 - Entraînement de zéro
-
- Prompting
 - RAG (Retrieval Augmented Generation)

07

Les outils (back)

Les outils

Frameworks de Deep Learning



Les outils

Frameworks de Deep Learning


```
# Récupération d'un modèle pré-entraîné
model0 = VGG16(include_top=False, weights="imagenet", input_shape=(224, 224, 3))
# Gel des couches non-entraînables
for layer in model0.layers:
    layer.trainable = False
# Récupération de la sortie du réseau de neurones
x = model0.output
# Complétion du modèle
x = GlobalAveragePooling2D()(x)
x = Dense(256, activation='relu')(x)
x = Dropout(0.5)(x)
predictions = Dense(4, activation='softmax')(x)
# Définition d'un nouveau modèle
model = Model(inputs=model0.input, outputs=predictions)
# compilation du modèle
model.compile(loss="categorical_crossentropy", optimizer='rmsprop', metrics=["accuracy"])
# Aperçu de la structure du modèle
print(model.summary())
```

Les outils

Frameworks de Deep Learning

Backends alternatifs à Tensorflow pour l'API Keras.

theano



Microsoft
Cognitive
Toolkit



plaidML

Les outils

Frameworks de Deep Learning

theano / Lasagne

Les outils

Frameworks de Deep Learning



Les outils

Frameworks de Deep Learning



```
1 import torch
2 from torch.utils.data import DataLoader, TensorDataset
3 from torch import nn
4
5 class SentimentLSTM(nn.Module):
6     def __init__(self, vocab_size, output_size, embedding_dim, hidden_dim, n_layers):
7         super(SentimentLSTM, self).__init__()
8         self.output_size = output_size
9         self.n_layers = n_layers
10        self.hidden_dim = hidden_dim
11
12        self.embedding = nn.Embedding(vocab_size, embedding_dim)
13        self.lstm = nn.LSTM(embedding_dim, hidden_dim, n_layers, batch_first=True)
14        self.fc = nn.Linear(hidden_dim, output_size)
15        self.sigmoid = nn.Sigmoid()
16
17    def forward(self, x, hidden):
18        batch_size = x.size(0)
19        x = self.embedding(x)
20        lstm_out, hidden = self.lstm(x, hidden)
21        lstm_out = lstm_out.contiguous().view(-1, self.hidden_dim)
22        out = self.fc(lstm_out)
23        out = self.sigmoid(out)
24        out = out.view(batch_size, -1)
25        out = out[:, -1]
26        return out, hidden
27
28    def init_hidden(self, batch_size):
29        weight = next(self.parameters()).data
30        hidden = (weight.new(self.n_layers, batch_size, self.hidden_dim).zero_(),
31                  weight.new(self.n_layers, batch_size, self.hidden_dim).zero_())
32        return hidden
33
34 # Parameters
35 output_size = 1
36 embedding_dim = 400
37 hidden_dim = 256
38 n_layers = 2
39
40 # Model, Loss, Optimizer
41 model = SentimentLSTM(vocab_size, output_size, embedding_dim, hidden_dim, n_layers)
42 loss_function = nn.BCELoss()
43 optimizer = torch.optim.Adam(model.parameters(), lr=0.001)
44
45 # Training loop (simplified)
46 epochs = 5
47
48 for epoch in range(epochs):
49     h = model.init_hidden(2)
```

Les outils

Frameworks de Deep Learning

```
# Récupération d'un modèle pré-entraîné
model0 = models.vgg16(pretrained=True)
# Gel des couches non-entraînables
for param in model0.parameters():
    param.requires_grad = False
# Définition du nouveau classificateur
class CustomVGG16(nn.Module):
    def __init__(self, base_model):
        super(CustomVGG16, self).__init__()
        self.base_model = nn.Sequential(*list(base_model.children())[:-2]) # Jusqu'à l'avant-dernier bloc
        self.global_avg_pool = nn.AdaptiveAvgPool2d((1, 1))
        self.fc1 = nn.Linear(base_model.classifier[0].in_features, 256)
        self.dropout = nn.Dropout(0.5)
        self.fc2 = nn.Linear(256, 4)
    def forward(self, x):
        x = self.base_model(x)
        x = self.global_avg_pool(x)
        x = torch.flatten(x, 1)
        x = torch.relu(self.fc1(x))
        x = self.dropout(x)
        x = self.fc2(x)
        return x
model = CustomVGG16(model0)
# Afficher le résumé du modèle
print(summary(model, (3, 224, 224)))
# Définir la fonction de perte et l'optimiseur
criterion = nn.CrossEntropyLoss()
optimizer = optim.RMSprop(filter(lambda p: p.requires_grad, model.parameters()), lr=0.001)
```

Les outils

Frameworks de Deep Learning

PyTorch vs. TensorFlow/Keras

- **Flexibilité/dynamisme**
- PyTorch est connu pour son approche dynamique des graphes de calcul (Dynamic Computational Graphs) : le "define-by-run". Les graphes sont construits à la volée, permettant une grande flexibilité et facilitant le debugging.
- TensorFlow, surtout dans ses versions antérieures à 2.0, utilise principalement des graphes statiques (Static Computational Graphs), où les graphes de calcul sont définis à l'avance. Cependant, TensorFlow 2.0 a introduit le mode "Eager Execution", permettant une exécution plus dynamique similaire à PyTorch.

Les outils

Frameworks de Deep Learning

PyTorch vs. TensorFlow/Keras

- **Facilité d'utilisation**
- Keras, surtout dans le contexte de `tf.keras`, est réputé pour sa simplicité et sa convivialité. Il est conçu pour permettre une création rapide de prototypes et une mise en œuvre facile des modèles.
- PyTorch est également apprécié pour sa facilité d'utilisation, en particulier pour les chercheurs et développeurs qui préfèrent un code pythonique et un debugging interactif.

Les outils

Frameworks de Deep Learning

PyTorch vs. TensorFlow/Keras

- **Écosystème**
- TensorFlow possède un vaste écosystème d'outils et de bibliothèques pour le déploiement, la production, l'optimisation, et bien plus encore (TensorFlow Lite, TensorFlow Serving, TensorFlow Extended).
- PyTorch possède également des outils pour le déploiement et l'optimisation, comme TorchServe pour le déploiement de modèles. PyTorch a également développé PyTorch Lightning et Fastai pour simplifier le développement de modèles complexes.

Les outils


Frameworks de Deep Learning

Caffe

Les outils

Frameworks de Deep Learning

Interopérabilité entre frameworks



ONNX

Les outils


Formats de fichiers

Nous avons dit que les frameworks ne sont pas interchangeables. Se pose la question du format de fichier.


Le GGUF (GPT-Generated Unified Format) est un format de fichier qui rationalise l'utilisation et le déploiement de grands modèles de langage (LLM). Le GGUF est spécialement conçu pour stocker des modèles d'inférence et fonctionner correctement sur du matériel informatique grand public.

Les outils

Industrialiser un modèle de ML ou un réseau de neurones



Les pipelines ML




Les pipelines en apprentissage automatique (ML) sont des séquences organisées d'étapes de traitement des données et de modélisation qui permettent de **structurer** et d'**automatiser** le flux de travail de création et d'évaluation des modèles. Les pipelines sont conçus pour rendre le processus de développement de modèles plus **efficace**, **reproductible** et **maintenable**. Ils aident également à éviter les erreurs humaines en automatisant les tâches répétitives et en garantissant la cohérence entre les différentes étapes du processus.


Un pipeline typique en ML comprend plusieurs étapes, telles que la préparation des données, l'ingénierie des fonctionnalités, la sélection du modèle, l'entraînement du modèle et l'évaluation des performances. Chaque étape est configurée de manière à prendre les données en entrée, à les traiter selon les besoins et à produire les sorties nécessaires pour la prochaine étape.

Les outils

Industrialiser un modèle de ML ou un réseau de neurones




La **CI/CD (Continuous Integration Continuous Deployment)** est un ensemble de **processus**, **outils** et **techniques** permettant de gérer la livraison des applications, de la production à la livraison en passant par le **build**, les **tests**, le **packaging**, et le **déploiement** grâce à des **pipelines automatisés**. Son but est d'augmenter la **fréquence** et la **rapidité** des livraisons.




Les outils

Industrialiser un modèle de ML ou un réseau de neurones



La **mise en place d'une CI/CD** se fait de manière **graduelle**. L'implémentation de processus solides d'intégration continue doit être priorisée avant de se concentrer sur l'automatisation des déploiements. On distingue **différents degrés d'automatisation de la CD**, qui font office de jalons vers le processus cible de déploiement en production.



Déploiement continu

- Chaque changement est livré directement en production
- Sans intervention humaine

Livraison continue

- Fusion entre intégration continue + déploiement automatisé

Déploiement automatisé

- Permet de déployer une version applicative sur un environnement défini

Intégration Continue

- Merge des modifications de code vers la branche principale le plus souvent possible
- Changements validés (ou non) grâce à une pipeline exécutant des tests et vérifications automatiques

Les outils

Industrialiser un modèle de ML ou un réseau de neurones


mlflow

APACHE


nifi



kafka



docker



APACHE
Spark™
hadoop



Fin de la formation

Merci !

Annexe 1


Métriques de performance

Définition d'une métrique de performance

Une **métrique de performance** est une mesure quantitative utilisée pour évaluer l'efficacité et la qualité d'un modèle ou d'un algorithme en termes spécifiques à la tâche à accomplir. Les métriques de performance permettent de quantifier objectivement la manière dont un modèle se comporte sur des données de test ou d'évaluation et d'obtenir des indications précises sur sa capacité à accomplir la tâche prévue.

Selon le domaine d'application et l'objectif du modèle, les métriques de performance varient. Par exemple, dans la classification, des métriques telles que la **précision**, le **rappel**, la **F-mesure** et l'**aire sous la courbe ROC** (AUC-ROC) évaluent la capacité d'un modèle à prédire correctement les classes d'une observation. Dans la régression, les métriques comme l'erreur quadratique moyenne (RMSE) et le coefficient de détermination (R^2) mesurent l'écart entre les prédictions du modèle et les valeurs réelles.

Les métriques de performance jouent un rôle crucial dans la sélection et l'évaluation des modèles. Elles aident les praticiens à **comparer différents modèles et méthodes**, à **ajuster les hyperparamètres**, et à **identifier les forces et les faiblesses d'un modèle particulier**. Le choix d'une métrique de performance dépend du problème à résoudre et des objectifs spécifiques de l'analyse. Il est important de sélectionner une métrique qui reflète fidèlement la performance souhaitée pour la tâche donnée.



Définition d'une métrique de performance

Baseline model

Un modèle simple est souvent utilisé comme **point de départ pour évaluer la performance des modèles plus complexes ou sophistiqués**. On l'appelle le modèle baseline.

Il agit comme une mesure de comparaison de base pour déterminer si un modèle plus avancé apporte des **améliorations significatives** par rapport à une méthode plus simple.

Par exemple, dans le domaine de la classification binaire, un modèle de référence simple pourrait être de prédire toujours la classe majoritaire. Pour la régression, un modèle de référence pourrait prédire simplement la moyenne de la variable cible pour tous les exemples.

En évaluant la performance de modèles plus avancés par rapport à celle du modèle de référence, on peut déterminer si les efforts investis dans le développement de modèles plus complexes ont un impact significatif sur les performances. Si le modèle sophistiqué ne parvient pas à surpasser le modèle de référence de manière significative, cela peut indiquer que des ajustements ou des améliorations sont nécessaires.

Les autres métriques

En plus des métriques de performance, il existe d'autres mesures et métriques qui peuvent être utiles pour évaluer et comprendre les résultats d'un modèle ou d'un algorithme dans différents contextes.

Coût : Cette métrique mesure les coûts associés aux erreurs de classification. Par exemple, dans la détection de fraude, le coût d'un faux positif (fausse alerte) peut être différent du coût d'un faux négatif (fraude non détectée). La prise en compte des coûts peut aider à ajuster les seuils de classification pour minimiser les pertes financières.

Similarité : Mesurer la similarité entre des observations peut être important dans des tâches telles que la recherche d'information, la recommandation ou la recherche de doublons. Des métriques comme la similarité cosinus, la distance de Jaccard, etc., quantifient à quel point deux observations sont semblables.

Stabilité : La stabilité mesure la robustesse d'un modèle ou d'un algorithme lorsque les données ou les conditions changent. Cela peut aider à évaluer la fiabilité des prédictions dans des environnements dynamiques.

Complexité : Mesurer la complexité d'un modèle est important pour éviter le surajustement. Des métriques comme le nombre de paramètres, la profondeur d'un arbre de décision, etc., peuvent être utilisées pour évaluer la complexité.

Temps d'exécution : Cette métrique mesure le temps nécessaire pour exécuter un algorithme ou réaliser des prédictions. Dans des applications en temps réel, le temps d'exécution peut être critique.

Interprétabilité : C'est un aspect difficile à mesurer directement, mais l'interprétabilité d'un modèle (dans quelle mesure il est compréhensible et peut être expliqué) en est une caractéristique essentielle. Des métriques comme la complexité du modèle ou l'importance des caractéristiques peuvent aider à évaluer l'interprétabilité.

Matrice de confusion


Faux positifs et faux négatifs

n=165	Predicted: NO	Predicted: YES	
Actual: NO	TN = 50	FP = 10	60
Actual: YES	FN = 5	TP = 100	105
	55	110	

Petit exercice : calculer la précision et le rappel.

$$F = 2 \cdot \frac{(\text{précision} \cdot \text{rappel})}{(\text{précision} + \text{rappel})} \quad (\text{moyenne harmonique})$$

$$F_{\beta} = \frac{(1 + \beta^2) \cdot (\text{précision} \cdot \text{rappel})}{(\beta^2 \cdot \text{précision} + \text{rappel})}$$



Matrice de confusion



Petit exercice : que dire d'un tel problème et d'un tel classifieur ?

	Predicted NO	Predicted YES
Actual NO	94	0
Actual YES	6	0

Courbes ROC et de lift

Pour évaluer et comparer les algorithmes

Une courbe ROC représente les taux de vrais positifs (TVP) et de faux positifs (TFP) à différents seuils de classification. En réduisant le seuil de classification, davantage d'éléments sont classés comme positifs, ce qui conduit à une augmentation à la fois du nombre de faux positifs et de vrais positifs.



Métriques de performance

Et pour la régression ?


$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$


$$R^2 = 1 - \frac{SS_{RES}}{SS_{TOT}} = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}$$

Descente de gradient stochastique

Minimisation de la métrique



$$x_{t+1} = x_t - \eta \times \nabla f(x_t)$$




Annexe 2

Du développement à la mise en production

Du développement à la mise en production

L'intégration continue




- **L'intégration continue** est une pratique dans laquelle les multiples développeurs d'un projet **commit leur code** dans un **repo partagé**, le plus souvent de manière quotidienne
- Un **workflow automatisé** est déclenché sur un **serveur de CI à chaque événement** de merge, de tag ou lors de builds planifiés (par exemple à midi ou le soir), afin de réaliser plusieurs vérifications sur le nouveau code poussé dans le repo.
- Si un **problème est détecté** sur le code, le serveur de CI **notifie les développeurs** de ces derniers pour anticiper tout problème de merge de branche



Du développement à la mise en production

L'intégration continue





Une CI est composée de **processus automatisés** permettant de :

- **Compiler le code** et exécuter des **tests** (unitaires notamment) pour s'assurer que les dernières modifications ne « cassent » pas certaines fonctionnalités de l'application
- **Scanner le code** pour s'assurer de sa qualité et du respect des bonnes pratiques de programmation (générales et spécifiques à l'entité)
- Générer et publier **un rapport** sur l'application et les derniers changements effectués sur celle-ci

Intégration continue




Développeurs



Du développement à la mise en production

Le déploiement continu




Le déploiement continu est une extension de la livraison continue, où les dernières modifications de code sont automatiquement préparées et vérifiées pour être déployées en production.

- Chaque modification de code est **déployée sur un environnement de test** après avoir été compilée
- Une **nouvelle série de tests** est effectuée sur l'application : tests fonctionnels, tests de l'interface utilisateur (UI) tests de performance, tests de sécurité, tests de performance, tests d'intégration, tests d'exploitation, etc
- Avec un pipeline de déploiement continu entièrement automatisée, **chaque modification de code** commit par les développeurs et passant avec succès chaque test est **déployée en production**

Déploiement continu / livraison continue




Opérations



Du développement à la mise en production

Pourquoi mettre en place une CI/CD



01

Déploiements fréquents et rapides

Cela permet de déployer plus fréquemment de nouvelles fonctionnalités, correctifs et améliorations, pour **répondre plus rapidement aux besoins des utilisateurs**.

02

Réduction des risques

En automatisant les processus de construction, de test et de déploiement, **les erreurs et les problèmes sont détectés plus tôt** dans le cycle de développement.

03

Collaboration renforcée

La CI/CD favorise la collaboration en encourageant le travail des développeurs sur une base de code commune et l'intégration régulière des modifications. Cela **réduit les conflits lors de l'intégration tardive du code** et **améliore la communication et la coordination** au sein des équipes.

04

Réduction des coûts et des délais

L'**automatisation** des processus de CI/CD permet de **réduire les tâches manuelles** et les **interventions humaines**. Cela **réduit les erreurs potentielles** et **accélère le déploiement des applications**, ce qui entraîne une réduction des coûts et des délais de développement.

05

Rétroaction rapide

L'utilisation de **tests automatisés systématiques**, et l'utilisation du **versioning** permet une rétroaction immédiate sur une **version antérieure** de l'application en cas de problème.



06

Scalabilité et flexibilité

La CI/CD facilite **l'adaptation** et **la mise à l'échelle des infrastructures** de développement et de déploiement. Elle permet de gérer facilement les variations de charge et les exigences croissantes en termes de déploiement d'applications sur différents environnements.


Du développement à la mise en production

Une pipeline complète de CI/CD



Du développement à la mise en production

Panorama général des outils de CI/CD



Stockage et gestion des versions



Analyse du code



Tests unitaires



Autres tests



Intégration et déploiement continu  Jenkins

Build



Infrastructure as code



Gestion des secrets



Monitoring



Gestion des logs



Packaging



Automatisation des déploiements



Outils d'infrastructure



Stratégie de maintenance corrective et évolutive

La maintenance corrective en ML consiste à **résoudre les problèmes** de performances, de précision ou de stabilité des modèles. Cela peut impliquer la correction de biais, de surajustement (overfitting) ou de sous-apprentissage (underfitting), ainsi que l'identification et la correction des erreurs de prédiction. Les méthodes de maintenance corrective en ML peuvent inclure la révision des ensembles de données, la mise à jour des algorithmes ou la reconfiguration des hyperparamètres.

La maintenance évolutive en ML vise à **intégrer de nouvelles fonctionnalités**, à améliorer les performances et à adapter les modèles aux nouvelles données et aux changements dans l'environnement. Cela peut impliquer la mise en place de pipelines d'apprentissage automatisés, l'ajout de nouvelles caractéristiques (features), l'intégration de techniques d'interprétabilité pour mieux comprendre les prédictions, ainsi que l'exploration de nouvelles méthodes d'apprentissage pour optimiser les performances.

Stratégie de maintenance corrective et évolutive

Pour appliquer une stratégie de maintenance corrective et évolutive en ML, les organisations adoptent généralement des pratiques telles que :

- la **surveillance continue des performances**, en mettant en place des métriques de suivi pour évaluer régulièrement la précision et la fiabilité des modèles en production,
- la **réévaluation des modèles**, en ré-entraînant les modèles régulièrement avec de nouvelles données pour s'assurer qu'ils restent pertinents et performants,
- l'**évaluation des nouvelles fonctionnalités**, en intégrant de nouvelles fonctionnalités en évaluant leur impact sur les performances et en effectuant des tests approfondis,
- la prise en compte du **feedback des utilisateurs**, en collectant les retours des utilisateurs pour identifier les lacunes et les améliorations possibles,
- la **documentation** et la **traçabilité**, en gardant trace des modifications apportées aux modèles, aux données et aux méthodes pour assurer le suivi et la compréhension.

Evaluation du coût de fonctionnement en production

L'évaluation des coûts de fonctionnement en production du Machine Learning (ML) est une étape cruciale pour assurer l'efficacité et la rentabilité de la mise en œuvre de modèles ML à grande échelle.

Cette évaluation consiste à estimer les coûts associés à l'**infrastructure informatique**, aux **ressources de calcul**, au **stockage des données**, à la **gestion des flux de données** en temps réel et aux coûts de maintenance.

En prenant en compte ces éléments, les entreprises peuvent optimiser leurs ressources, anticiper les besoins et prendre des décisions éclairées pour maintenir les modèles ML en production de manière efficace et économique.

Les clouders proposent tous un dashboard de suivi des coûts. Il faut faire particulièrement attention au dimensionnement en échelle et en temps des services utilisés.

Annexe 3

Zoom sur Spark

Zoom sur Spark



Slides extérieurs à cette présentation

Annexe 4

Zoom sur Kafka

Zoom sur Kafka



Slides extérieurs à cette présentation